

B-MODE 초음파 · 의사결정지원 영상표지자

B-mode 초음파에서 HCC 유사도를 정량화하는 이중 출력 영상표지자의 개발

HCC Cosine Score와 Confidence Score의 상호보완적 임상적 의의

예수병원 가정의학과 R3 김현수

1.000

AUROC

0

HCC 위음성

2,656

초음파 영상 (clean subset)

연구 배경

HCC 감시에서 초음파의 민감도 한계

B-mode 초음파는 고위험군 HCC 감시의 일차 도구이나, 조기 병변에 대한 민감도가 제한적이며 검사자 의존성이 크다.

- 초음파 단독 조기 HCC 민감도
- AFP 병용 시에도 개선이 제한적

Tzartzeva K, et al. Gastroenterology 2018

47%
초음파 단독

63%
AFP 병용 시

연구 배경

HCC와 혈관종은 클래스 내 이질성이 크다

HCC

전체의 10-15%가 비전형 소견
고분화 HCC가 고에코성 혈관종 패턴을 모사

혈관종

비전형 혈관종이 악성을 모사
저에코 테두리·이질적 에코·경계 불명

- ▶ AFP 상승을 동반한 비전형 혈관종이 HCC로 오진된 증례도 보고됨

Minami 2023 · Chou 2017 · Sirli 2015

연구 배경

임상 판독은 유사성 기반 추론이다

임상의는 단순한 이진 결정이 아닌, "이 병변이 전형적 HCC와 얼마나 닮았는가"를 평가하는 연속적 추론을 수행한다.

LR-3

중간 위험

LR-4

높은 위험

LR-5

전형적 HCC

LI-RADS 역시 연속적 위험 단계로 구성되며, 임상 판독은 본래 스펙트럼 위에서 이루어집니다.

ACR LI-RADS v2018

연구 배경

기존 딥러닝 모델의 구조적 한계

- 단일 softmax 출력을 확률로 해석 → 보장되지 않은 과잉 확신
- 비전형 병변을 별도 표시하는 기능 부재
- 전형·비전형 병변이 동일 출력 범위에서 처리

Guo 2017 · Liu 2019

기존 AI 출력

병변 → HCC 확률



"전형 HCC와의 닮은 정도" 정보가 소실

연구의 새로움 (NOVELTY)

"답은 정도"를 연속형 영상표지자로 정량화

단일 분류 출력을 넘어, 임상의의 유사성 기반 추론을 수치화한 이중 출력 표지자를 B-mode 초음파에서 도출하는 학습·분석 체계를 제안한다.

① 새로운 표지자

HCC Cosine Score, Δscore
— 비전형성을 연속값으로 정량화

② 출력 해석론 전환

softmax를 확률이 아닌 결정 강도로 재정의

③ 학습 전략 검증

SupCon의 필수성 및 소규모 데이터에서 SSL 한계 실증

연구 개요

한눈에 보는 연구 설계

- 데이터: SMC-LUD (744명, 2,656영상 · clean subset)
- 모델: EfficientNetV2B0 + 4겹 Transformer encoder
- 학습: 교차 엔트로피 + Supervised Contrastive Learning
- 출력: Confidence / HCC Cosine / Δ score

주요 결과

1.000
AUROC

0
HCC 위음성

애매 구간에서 오답 구제(salvage) 효과 확인

02

대상 및 방법

Materials and Methods — 데이터, CNN·ViT·임베딩 기초, 모델 구조, Cosine Score 산출, 손실 함수, 학습 전략

대상 및 데이터

SMC-LUD clean subset — 학습·평가에 사용된 데이터

744

명 환자

2,656

장 영상

- 병리확진 HCC 1,389장
- 영상진단 혈관종 1,267장
- 환자 단위 분할로 데이터 누수 차단

Train / Val / Test 분할					
	환자	영상	Train	Val	Test
혈관종	323	1,267	886	253	128
HCC	421	1,389	972	277	140
합계	744	2,656	1,858	530	268

원 데이터셋 SMC-LUD 1,021명 5,385장(Tak J, et al. Sci Data 2026) 중 품질 기준 통과 clean subset

딥러닝 기초 ①


두 종류의 영상 AI: CNN과 Transformer(ViT)

CNN — 필터가 이미지를 훑으며 국소 패턴 추출



국소 특징 수집 (에코·경계 등)

ViT — 이미지를 패치로 나누고 전역 문맥 파악



패치 간 attention → 전역 관계 학습


본 연구는 두 방식을 결합(hybrid) — CNN으로 국소 특징을, Transformer로 전역 문맥을 함께 추출한다.

딥러닝 기초 ②

임베딩 — 영상을 "숫자 좌표"로 요약


- 영상 → 신경망 → 고차원 숫자 벡터로 압축
- 비슷한 영상은 가까이, 다른 영상은 멀리
- 이 "위치"가 **낮은 정도**를 재는 기준이 됨

임베딩 공간에서의 거리·각도 = 영상 간 의미적 유사도. 본 연구는 이를 cosine similarity로 정량화한다.



모델 구조


EfficientNetV2B0 말단에 4겹 Transformer encoder 부착



CNN이 잡은 국소 특징을 Transformer 4겹이 전역적으로 재조합 → 하나의 임베딩 벡터에서 두 종류의 점수를 동시 산출

COSINE SCORE 산출 방법

"전형적 HCC와 얼마나 닮았나" = 두 벡터의 각도



Cosine similarity = 두 벡터가 이루는 각도 θ 의 코사인 값

닮을수록(같은 방향) 각도가 작아지고 cosine $\uparrow$ (최대 1)

- HCC prototype 4종과의 유사도 평균 = HCC score
- 혈관종 prototype 4종과의 유사도 평균 = 혈관종 score
- 둘의 차이 = Δ score (어느 쪽에 더 가까운가)

손실 함수

교차 엔트로피 + Supervised Contrastive Learning

총 손실 = 분류 손실 + 유사도 정렬 손실

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \lambda \mathcal{L}_{\text{SupCon}}$$

교차 엔트로피 $\mathcal{L}_{\text{CE}}$ — 정답 클래스 확률을 최대화하여 분류 경계 형성

$$\mathcal{L}_{\text{CE}} = - \sum_{c=1}^C y_c \log p_c$$

p_c : softmax 출력(클래스 c 확률) · y_c : one-hot 정답 라벨

SupCon $\mathcal{L}_{\text{SupCon}}$ — 같은 병변은 가까이, 다른 병변은 멀리

$$\mathcal{L}_{\text{SupCon}} = \sum_i \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(\mathbf{z}_i \cdot \mathbf{z}_p / \tau)}{\sum_{a \in A(i)} \exp(\mathbf{z}_i \cdot \mathbf{z}_a / \tau)}$$

$\mathbf{z}_i, \mathbf{z}_p$

임베딩 벡터 (정규화)

$P(i)$

i 와 같은 클래스 표본 집합

τ, λ



temperature · 손실 가중치

손실 함수의 작동 방식

CE는 "경계"만, SupCon는 "구조"를 만든다

SupCon vs CE — 임베딩 공간에서의 작동 방식

CE only — 경계만 형성 CE + SupCon — 응집 + 분리



CE는 클래스가 경계 너머에 있기만 하면 충분 → 임베딩 구조 무관. SupCon는 같은 병을 한 점으로 응집시켜 cosine score의 근거를 형성

학습 전략 및 ABLATION 설계

세 가지 학습 조건 비교

CE only

교차 엔트로피 손실로 분류 경계 형성. 임베딩 구조는 학습 목적이 아님.

CE + SupCon

동일 클래스는 가까이, 타 클래스는 멀리. 임베딩에 응집성
· 분리성 부여.

NNCLR 2단계

레이블 없는 사전학습 → CE+SupCon 미세조정. SSL 추가 효용 검증용.

Ablation 목적 ▶ (1) SupCon이 cosine 표지자의 타당성을 확보하는가, (2) SSL 사전학습이 추가 이득을 주는가를 동시에 검증

Khosla 2020 · Geirhos 2020

이중 출력 표지자 정의

세 가지 출력의 임상적 의미

①

Confidence score

HCC softmax 값. 확률이 아닌
결정 강도로 정의

②

HCC Cosine score

HCC prototype 4종과의 평균
유사도 = "전형 HCC와의 닮은
정도"

③

Δ score

HCC 닮음 - 혈관종 닮음. 두 클
래스 간 상대적 위치

▶ 임계값은 검증 세트에서만 Youden's J로 결정 후 테스트 세트에 고정 적용하여 낙관적 편향 배제

Chen 2019 · Li 2018 · DeLong 1988

03

결과

Results — 주력 모델 성능, 이중 출력 비열등성, SupCon 필요성, 애매 구간 구제 효과, SSL 한계

결과 ① 주력 모델 성능

거의 완벽한 감별, HCC 위음성 0건

1.000
AUROC (val·test)

100%
테스트 민감도

99.2%
테스트 특이도

99.6%
정확도

Test 혼동행렬


	예측 혈 관종	예측 HCC
실제 혈 관종	127	1
실제 HCC	0	140

위양성 1건, 위음성 0건


동일 데이터셋 선행연구 baseline 정확도 98.88%를 상회

결과 ② 세 출력의 일치


Confusion Matrix — 세 출력 모두 위음성 0건



① Confidence score



② HCC cosine score




③ Δ score

세 출력이 동일한 판정 — cosine 기반 표지자가 주 출력과 동등한 분류 수행

결과 ③ 임베딩 공간 시각화

t-SNE — 두 질환이 명확히 분리




- HCC와 혈관종이 뚜렷이 분리
- 같은 병변끼리 단단히 응집 = SupCon 효과
- 별표 = 각 군집의 prototype (대표 견본)

"닮은 정도" 점수가 신뢰하려면 같은 병이 같은 자리에 모여야 하며, 이 시각화가 이를 확인한다.

Figure 1 · t-SNE visualization (test set)

결과 ④ 비열등성 검증

세 ROC가 AUROC 1.000에서 완전 중첩




출력	AUROC	DeLong p
① Confidence	1.000	— (기준)
② HCC cosine	1.000	1.000
③ Δ score	1.000	1.000

차이가 통계적으로 유의하지 않음 → cosine 표지자는 confidence score와 동등한 변별력

Figure 3 · Triple ROC (Test). DeLong 검증

결과 ⑤ SUPCON의 필요성

진짜 HCC에서 HCC 닮음 점수가 유의 상승



- SupCon 적용 시 HCC cosine score **유의 상승**
- 두 backbone 모두 $p < 0.001$
- 같은 병이 더 단단히 응집 → 점수의 임상적 타당성 확보

Δ score(두 그룹 간 거리)는 유의 변화 없음 — 간 실질·초음파 modality의 공통 배경이 양쪽에 강하게 작용한 것으로 추정

Figure 4 · True HCC cases (val+test, $n=381$)

결과 ⑥ 핵심 발견

애매 결정 구간에서 cosine 표지자의 구제(salvage) 효과

confidence score 0.4-0.6, 가장 애매한 결정 경계 부근

일반 분류 모델

4 / 7

HCC를 위음성으로 오분류

정확도 42.9%

+ cosine 표지자 (SupCon)

5 / 5

모두 HCC로 정확 식별

정확도 100% (FN=0)

의의 ▶ 단일 출력이 내리지 못하는 판정을 임베딩 공간의 "뉘은 정도"가 보완 — 비전형 케이스 감별에서 이중 출력의 임상적 보완 효용 입증

결과 ⑦ SSL 사전학습의 한계

NNCLR 2단계 학습 — 성능 향상 없이 오히려 붕괴

전 모델 비교 (Test, HCC cosine AUROC)

모델·학습	Conf.	HCC cosine
Eff · CE	1.000	1.000
Eff · CE+SupCon	1.000	1.000
Eff · NNCLR	1.000	0.893
Res · NNCLR	0.999	0.068

- 사전학습 추가 시 cosine 표지자 붕괴 (최악 0.068)
- 분류 성능 향상 없음
- 추가 학습 시간·계산 자원 정당화 불가

시사점 ▶ 소규모 의료 영상에서는 레이블 기반 지도 학습(CE+SupCon)이 우월

Table 4B · NNCLR = 사전학습 후 CE+SupCon 미세조정 2단계

04

고찰

Discussion — 임상적 의의, 출력 해석론 전환, 연구의 한계

임상적 의의

연속형 점수가 제공하는 네 가지 임상 가치

① 비전형 병변의 triage

이진 출력이 놓치는 애매 케이스를 "뉘는 정도"로 보완. 추가 검사가 필요한 병변 식별

② 임상 추론과 모델 추론의 일치

임상의의 유사성 기반 추론·의사결정 방식을 딥러닝 모델의 출력 구조에 일치시키려는 설계

③ 출력 해석론 전환

softmax를 확률이 아닌 결정 강도로 재정의 — 과잉 확신 경고

④ 실용적 학습 원칙

소규모 의료 데이터에서는 지도학습 우선. 사전학습은 대규모 데이터에서 의미

남은 과제와 추가 연구 방향

한계 (Limitations)

- 단일 기관 공개 데이터셋 — 외부 일반화 미검증
- 인구통계(병변 크기·간경변·AFP) 미반영
- HCC cosine score의 AFP 대비 독립 기여 미평가

향후 연구 (Future Works)

- 외부 다기관 데이터 일반화 검증
- AFP 등 임상 변수와의 병용·독립 기여 평가
- NNCLR/SSL 하이퍼파라미터 민감도 분석
- 임상 변수 통합 모델 및 추가 코호트 확장

▶ AUROC 1.000은 동일 데이터 내 결과 — 외부 데이터 일반화 검증이 다음 관건

결론

임상의의 유사성 기반 추론을 수치화한 영상표지자를 제안하였으며,
그 임상적 유효성을 확인하였다.

1.000

AUROC, HCC 위음성 0건

동등

cosine vs confidence (DeLong)

구제

애매 구간 오답 보완

향후 과제: 외부 다기관 검증 · AFP 대비 독립 기여 평가 · SSL 민감도 분석

감사합니다. 질문과 토론을 환영합니다.

김현수 · 예수병원 가정의학과 · github.com/kimhs950627/hcc-vs-hemangioma