시간 배분

· 슬라이드 (eyebrow) · 배분

1 — 표지 · 15초

2 — What is your diagnosis? (임상 배경) · 50초

3 — 그 76%는 어디서 온 숫자인가 (근거) · 35초

4 — 확률이 아니라 "닮음" (방법) · 50초

5 — 인코더 내부 (방법) · 15초

6 — SupCon은 임베딩의 모양을 바꾼다 (방법) · 30초

시간 배분 계속

7 — 확률 0.5는 위음성 6, 닮음 지표는 위양성 1 (결과) · 70초

8 — 닮음 점수가 실제로 움직였다 (결과) · 25초

9 — 혈관종처럼 보이는 HCC 4예 (결과) · 40초

10 — 차이는 유의하지 않다 — 실패 지점이 다르다 (고찰 ①) · 55초

11 — Novelty와 한계 (고찰 ②) · 50초

12 — 감사 · 10초

— **합계** · **7분 25초** (+ 전환 35초 = 8분)

§1 표지

15초

안녕하십니까. 예수병원 가정의학과 R3 김현수입니다. B-mode 복부 초음파에서 간암과 간혈관종을 감별할 때 쓰는 **확률 하나에 "유사도 점수"라는 두 번째 숫자를 더한** 탐색적 연구입니다. 8분으로 줄여서 **임상 결론 중심**으로 말씀드리고, **공학적 세부는 질의 시간에** 답하겠습니다.

> **무대**
> 제목·소속만 짚고 넘어간다. 8분이라는 말로 기대치를 먼저 맞춘다.

§2 What is your diagnosis?

50초

네 장 모두 B-mode 복부 초음파입니다. 혈관종의 전형은 고에코, 경계 명확, 후방음영 증가인데 — **(클릭)** — 네 장 모두 **간암**입니다. 고분화 HCC가 혈관종의 전형을 그대로 흉내 냅니다.

얼마나 어려운지 숫자 하나로 보겠습니다. 2020년 다기관 연구에서, 15년 경력 판독자가 임상정보를 받은 상태의 악성·양성 감별 정확도가 **76.0%** 였습니다.

미리 분명히 해 두겠습니다. 이 연구는 **감시나 선별이 아닙니다.** 이미 발견된 병변을 간암과 혈관종으로 가르는 **감별 보조**입니다.

> **무대**
> 네 컷에는 라벨이 없다. 하나씩 짚고 클릭해 공개한다.

§3 그 76%는 어디서 온 숫자인가

35초

그 76%의 출처입니다. 중국 13개 병원 **전향적 다기관** 연구이고, 15년 이상 경력 전문의 **236명**이 익명화된 동영상을 임상정보와 함께 독립 판독했습니다.

다만 **악성 대 양성 이분**이고 양성이 19.3%뿐이며, **실제 진료가 아닌 동영상 판독 과제**였습니다. 이 두 가지 한계를 안고 읽어야 합니다.

> 무대
> 사람 성적의 조건을 먼저 깔아 둔다. 뒤에서 AI 수치를 말할 때 비교선이 된다.

§4 확률이 아니라 "닮음"

50초

그 연구는 한 가지를 더 보여줍니다. **영상에 임상정보를 결합한 AI는 84.7%였고, 영상만 쓴 모델은 판독자와 같은 76.0%**였습니다. 즉 **이득은 영상이 아니라 임상정보에서** 왔습니다.

그런데 **지금 대부분의 AI는 confidence 한 숫자만 내고, 그 값으로 label을 정합니다.** 그 숫자가 틀리면 판독자는 검증할 수단이 없습니다.

그래서 **세 개의 output**을 내는 모델을 만들었습니다.

- **Confidence** — 지금까지 AI가 내던 softmax 값. 보정이 안 된 값이라 확률이 아니라 **결정 강도**로 부릅니다.

§4 확률이 아니라 "닮음"

50초 계속

- **HCC cosine** — **전형 HCC와 얼마나 닮았는지**, 즉 **전형성**입니다.
- **Δscore** — HCC cosine에서 혈관종 cosine을 뺀 값, **어느 쪽에 더 가까운가**입니다.

데이터는 공개 데이터셋 SMC-LUD clean subset, **744명 2,656장**을 **환자 단위**로 나눴습니다.

> **무대**
> 이미지 → 인코더 → 임베딩 → 세 지표 흐름을 한 번만 보여준다.

§5 인코더 내부

15초

구조는 한 줄로만 말씀드리겠습니다. 왼쪽은 합성곱이 특징 맵을 채우고, 오른쪽은 **CLS 토큰이 패치를 하나로 종합**합니다. 중요한 것은 **세 지표가 전부 이 임베딩 하나에서 나온다**는 점입니다. **모델 구조와 학습 설정은 질의 시간에 자세히 설명드리겠습니다.**

> **무대**
> 여기서 절대 멈추지 않는다. 15초 안에 다음 장으로 넘어간다.

§6 SupCon은 임베딩의 모양을 바꾼다

30초

코사인은 SupCon 없이도 계산됩니다. 다만 그때 값은 흩어져 있어 **증례별로 읽을 수가 없습니다.** SupCon을 걸면 **같은 클래스는 모으고 다른 클래스는 밀어냅니다** — 미학습 HCC의 **94.7%에서 점수가 올라가고**, 코사인이 **증례별로 쓸 수 있는 값**이 됩니다. 분포와 검정 수치는 **질의 시간에** 말씀드리겠습니다.

대가는 Δscore 감소이고, 뒤에서 짚겠습니다.

> **무대**
> 수치·p값은 읽지 않는다. "읽을 수 있는 값이 됐다" 한 문장만 남긴다.

§7 같은 모델, 두 운영점

70초

성능입니다. 왼쪽 표의 두 열만 보시면 됩니다. 왼쪽은 관행대로 **확률을 0.5에서**, 오른쪽은 닮음 지표를 **검증 세트에서 고른 값**에서 잘랐습니다 — 사실상 Youden 구간의 위쪽 끝이라, 검증 HCC 중 가장 낮은 점수입니다.

확률 쪽은 HCC 여섯 장을 놓치고, 닮음 쪽은 혈관종 한 장만 HCC로 올립니다. 즉 **어디서 자르느냐가 민감도와 특이도를 맞바꿉니다.**

두 가지를 분명히 하겠습니다. 첫째, **두 운영점의 차이는 유의하지 않습니다** — 불일치가 여섯 대 하나, McNemar p는 0.125로 0.05보다 큽니다. 둘째, 세 출력의 AUROC가 모두 1.000이라 **DeLong 검정이 정보를 주지 않습니다.** 그래서 **우월도 비열등도 주장하지 않습니다.**

§7 같은 모델, 두 운영점

70초 계속

오른쪽 표의 컷오프와 등가 구간은 **둘 다 검증 세트에서** 구했습니다. 등가 구간은 같은 혼동행렬을 내는 임계값의 폭이고, 컷오프는 언제나 그 안에 있습니다 — 닮음 지표는 구간의 위쪽 끝이 곧 컷오프입니다.

테스트에서는 혈관종 한 장이 그보다 조금 위로 올라와 위양성이 한 건 났는데, **테스트에 맞춰 컷오프를 올리지는 않았습니다.** 그래서 외부 코호트에서 다시 정해야 합니다.

> **무대**
> "동등/비열등/개선"은 입에 올리지 않는다. 표의 두 열만 손으로 짚는다.

§8 닮음 점수가 실제로 움직였다

25초

왼쪽은 실제 HCC의 코사인 분포입니다. SupCon 후 **0.9 근처로 모이고**, 상승은 **전형에서 멀던 증례**에서 컸습니다 — 하위 10%가 크게 올라왔습니다. 즉 **아리까리했던 증례가 전형 HCC 쪽으로 정렬**된 것입니다. 다만 이건 **해석의 근거**이고 **성능이 좋아졌다는 근거가 아닙니다.** 분포 통계는 질의 시간에 말씀드리겠습니다.

> **무대**
> 25초. 여기서 멈추면 §7의 결론이 약해진다. 한 문장씩만.

§9 혈관종처럼 보이는 HCC 4예

40초

혈관종처럼 보이는 HCC 4예를 실제로 넣어 봤습니다. 문헌에 보고된 고에코 HCC — 후방강화 동반, halo, 혈관종과 나란히 — 사람이 봐도 어려운 것들입니다. **세 출력 모두 4예 전부 HCC로 분류했습니다.**

다만 **proof-of-concept**입니다. n이 4이고, 출판 figure에서 온 저해상도·타 장비 영상이라 domain shift가 큽니다. **민감도 추정치로 읽으면 안 됩니다.**

§10 차이는 유의하지 않다 — 다만 실패하는 지점이 다르다

55초

가장 중요한 슬라이드입니다. 표에 두 줄만 있습니다.

첫 줄 — 확률 0.5가 놓친 HCC 여섯 장은, **같은 케이스의 닮음 점수가 모두 HCC 쪽**입니다. 확률만 경계에 눌린 것입니다.

둘째 줄 — 닮음 지표의 유일한 위양성은 실제 혈관종 한 장이고, 그 장은 **확률로는 정답**이 되는 케이스입니다.

정리하면 **실패하는 케이스가 서로 다릅니다.** 다만 차이는 유의하지 않으므로 — 불일치 여섯 대 하나, p는 0.125 — **닮음 지표가 확률을 개선한다고 주장하지 않습니다.** 확률이 애매한 구간에서 보조 판단을 주는 **새 지표**로 제안하고, 컷오프는 외부 코호트에서 다시 계산하는 것을 전제로 둡니다.

> **무대**
> '개선'이라는 단어를 쓰지 않는다. '다른 지점에서 실패한다'까지가 오늘의 결론이다.

§11 Novelty와 한계

50초

남은 것은 — **한 모델에서 확률과 닮음 판단을 케이스 단위로 함께 낸다**는 것, **판독자가 이미 하는 "닮음" 판단을 숫자로 남긴다**는 것, 그리고 **지표마다 운영점과 등가 구간을 함께 제시한다**는 것입니다.

한계는 분명합니다. **단일기관이라 외부 검증이 없습니다. AUROC가 1.000이라 최적 컷오프가 유일하지 않고**, 두 운영점의 차이도 유의하지 않습니다.

Δscore는 오히려 감소했고, 닮음 상승은 SupCon 목적함수의 귀결이지 임상 타당성의 독립 증거가 아닙니다. 배경 간 정보가 없어 층화가 불가능하고 단축경로 학습 가능성도 배제할 수 없습니다.

§11 Novelty와 한계

50초 계속

지금 데이터로는 **성능 차이가 유의하지 않습니다.** 그래서 이 지표의 값어치는 **추가 연구에서만** 정해집니다. 후속 연구에서 닮음 점수가 유의하게 도움이 된다면, **혈관종으로 follow-up 하기로 한 케이스 안에 섞여 있을 수 있는 HCC를 구제**하는 데 쓸 수 있습니다. 다만 이건 **가설**이고, 오늘 수치로는 아무것도 보장하지 않습니다.

다음 단계는 **다기관 외부 검증에서 컷오프 재산출, 판독자 대상 전향적 비교, AFP·조영증강 영상과의 비교**입니다.

§11 Novelty와 한계

50초 계속

> 질문 시 답변(말하지 않고 대기): 닮음 점수의 정의는 병변 임베딩과 학습 데이터 전형 프로토타입의 **코사인 유사도 평균**이고, 소프트맥스 확률이 아니며 보정된 확률도 아니다. Grad-CAM을 왜 안 넣었는지 물으면: 배경 간 라벨이 없으면 heatmap이 병변을 보는지 배경을 보는지 구분할 수 없어 오해를 만들 수 있다고 답한다.

§12 감사

10초

이상입니다. 오늘 말씀드린 것은 두 가지입니다. **닮음 점수라는 두 번째 숫자를 만들었다**는 것, 그리고 **그 숫자가 아직 임상적 이득을 입증하지 못했다**는 것.

마지막 장 QR은 **지금 이 자리에서 돌려볼 수 있는 웹 데모**입니다. 설치도 로그인도 필요 없고 사진은 기기 밖으로 나가지 않습니다.

질문과 토론을 환영합니다. 감사합니다.