시간 배분

· 슬라이드 (eyebrow) · 배분

1 — 표지 · 20초

2 — What is your diagnosis? (임상 배경) · 55초

3 — 그 76%는 어디서 온 숫자인가 (근거) · 45초

4 — 확률이 아니라 "닮음" (방법) · 45초

5 — 인코더 내부 (방법) · 40초

6 — SupCon은 임베딩의 모양을 바꾼다 (방법) · 60초

시간 배분 계속

7 — 테스트 268장 — 위음성 0, 위양성 1 (결과) · 65초

8 — 닮음 점수가 실제로 움직였다 (결과) · 55초

9 — 혈관종처럼 보이는 HCC 4예 (결과) · 40초

10 — 증분 이득은 없었다 (고찰 ①) · 55초

11 — Novelty와 한계 (고찰 ②) · 50초

12 — 감사 · 20초

— **합계** · **9분 10초**

§1 표지

20초

안녕하십니까. 예수병원 가정의학과 R3 김현수입니다. 이번 대한가정의학회 추계학술대회에서, B-mode 복부 초음파에서 간암과 간혈관종을 감별할 때 쓰는 **확률 하나에 "유사도 점수"라는 두 번째 숫자를 더한** 탐색적 연구를 발표하겠습니다.

> 무대
> 제목과 소속만 짚고 바로 넘어간다.

§2 What is your diagnosis?

55초

네 장 모두 B-mode 복부 초음파입니다. 혈관종의 전형은 고에코, 경계 명확, 후방음영 증가인데 — **(클릭)** — 네 장 모두 **간암**입니다. 고분화 HCC가 혈관종의 전형을 그대로 흉내 냅니다.

얼마나 어려운지 숫자로 보겠습니다. 2020년 EBioMedicine 다기관 연구에서, 15년 경력 초음파 판독자가 임상정보를 제공받은 상태에서 악성과 양성을 감별한 정확도가 **76.0%**였습니다.

미리 분명히 해 두겠습니다. 이 연구는 **감시나 선별 검사가 아닙니다.** 영상에서 **이미 발견된 병변**을 간암과 혈관종으로 가르는 **감별 보조**를 다룹니다.

> 무대
> 네 컷에는 라벨이 없다. 하나씩 짚으며 판독을 물은 뒤 클릭해 공개한다.

§3 그 76%는 어디서 온 숫자인가

45초

방금의 76%가 어디서 온 숫자인지 짚겠습니다.

중국 13개 병원 **전향적 다기관** 연구입니다. 외부검증 338 병변에서 15년 이상 경력 초음파 전문의 **236명**이 익명화된 **10~20초 동영상**을 임상정보와 함께 독립 판독했습니다. 정확도 **76.0%**, 민감도 **76.1%**, 특이도 **76.9%** — 이게 사람의 성적입니다.

다만 **악성 대 양성 이분**이고 양성이 **19.3%**뿐이며, **실제 진료가 아닌 동영상 판독 과제**였습니다.

> **무대**
> 2장의 76%를 의심할 지점을 여기서 먼저 막는다.

§4 확률이 아니라 "닮음"

45초

방금 그 연구는 두 가지를 같이 보여줍니다. **영상에 임상정보를 결합한 AI가 84.7%로 15년 경력 판독자의 76.0%를 유의하게 넘었고, 조영증강 CT와 동등했습니다** — 둘 다 84.7%입니다.

즉 **B-mode 단일 과제에서 AI는 판단에 도움이 됩니다.** 다만 정직하게 말하면 **영상만 쓴 모델은 76.0%로 판독자와 같았습니다.** 이득은 영상이 아니라 임상정보에서 왔습니다.

그런데 **지금 대부분의 AI는 confidence 한 숫자만 내고, 그 값으로 label을 정합니다.** 그 숫자가 틀리면 판독자는 검증할 수단이 없습니다. 그래서 저희는 **세 개의 output을 내는 모델**을 만들었습니다. 영상이 인코더를 지나 임베딩이 되고, 거기서 세 개의 숫자가 나옵니다.

§4 확률이 아니라 "닮음"

45초 계속

- **Confidence** — 지금까지 AI가 내던 softmax 값입니다. 보정이 안 된 값이라 확률이 아니라 **결정 강도**로 부릅니다.
- **HCC cosine** — **전형 HCC와 얼마나 닮았는지**, 즉 **전형성(typicality)** 입니다. 확률이 아니라 닮음의 값입니다.
- **Δscore** — HCC cosine에서 혈관종 cosine을 뺀 값, **어느 쪽에 더 가까운가**입니다.

데이터는 공개 데이터셋 SMC-LUD의 clean subset, **744명 2,656장**이고 — train 1,858 / val 530 / test 268 — **환자 단위**로 나눴습니다.

> 무대
> 애니메이션이 이미지 → 인코더 → 임베딩 → 세 지표로 흐르는 것을 한 번 보여준다.

§5 인코더 내부

40초

왼쪽은 **3×3 합성곱 필터가 초음파 영상 위를 한 칸씩 미끄러지며** 특징 맵을 채웁니다. 오른쪽은 **CLS 토큰이 패치마다 가중치를 주며 하나로 종합**합니다.

중요한 건 **세 지표가 전부 이 CLS 임베딩 하나에서 나온다**는 점입니다. 모델은 EfficientNetV2B0 **7.1M**으로, 23.6M짜리 ResNet50V2와 같은 AUROC를 냈습니다.

> 무대
> 공학 설명은 여기서 끝낸다.

§6 SupCon은 임베딩의 모양을 바꾼다

60초

코사인은 SupCon 없이도 계산됩니다. 그런데 그때 값은 −0.5에서 1까지 흩어져 **증례별로 읽을 수가 없습니다.** 간암인데 코사인이 0.4인 증례가 있습니다 — 그걸 "간암스럽다"고 말할 수는 없습니다.

SupCon을 걸면 **같은 클래스는 모으고 다른 클래스는 밀어냅니다.** 미학습 HCC 417예 중 **94.7%에서 점수가 올라가고**, 하위 10%는 0.49에서 **0.76**으로, 최솟값은 −0.47에서 −0.005로 올라옵니다. 분산은 **60.7%** 줄었습니다.

§6 SupCon은 임베딩의 모양을 바꾼다

60초 계속

즉 SupCon은 코사인을 **증례별로 쓸 수 있는 값**으로 만듭니다 — 전형에서 멀던 증례가 전형 쪽으로 정렬됩니다. 다만 **Δscore는 1.508에서 1.076으로 오히려 줄었습니다.** 뒤에서 설명드리겠습니다.

> **무대**
> 여기가 이 발표에서 "정직한 음성 결과"를 처음 꺼내는 지점이다. 상승폭·유의성은 슬라이드 각주에 있으니 읽지 말고 가리키며 말한다.

§7 테스트 268장 — 위음성 0, 위양성 1

65초

성능입니다. 테스트 268장에서 AUROC 1.000, 민감도 100%, 특이도 99.2%, 정확도 99.63%입니다.

두 가지를 강조하겠습니다. 첫째, 특이도 99.2%의 신뢰구간은 **95.7에서 100**이고, 영상 단위로 계산해 **실제보다 좁게 나왔을 수 있습니다.** 둘째, **세 출력의 AUROC가 모두 1.000**이고 세 곡선이 완전히 겹쳐, DeLong 검정이 아무 정보도 주지 않습니다.

그래서 **"동등"이나 "비열등"을 주장하지 않고**, AUROC가 천장이라 **우열을 판정할 수 없다**고만 말합니다.

> 무대
> "동등/비열등"은 절대 입에 올리지 않는다.

§8 닮음 점수가 실제로 움직였다

55초

왼쪽은 실제 HCC 417장의 코사인 분포입니다. SupCon 없이는 0과 1 사이에 **넓게 퍼져 있어** "HCC스럽다"고 말할 수가 없습니다. SupCon 후에는 **0.9 근처로 모이고**, 분산은 60.7% 줄었습니다. 오른쪽 혈관종 381장도 0.955에서 0.985로 같은 방향입니다.

여기서 중요한 건 **상승이 어디에 일어났는가**입니다. 하위 10%가 0.49에서 0.76으로 오르는 동안 상위 10%는 0.95에서 0.99로 거의 움직이지 않았습니다. **전형에서 멀던, 아리까리했던 증례들이 전형 쪽으로 온 것**입니다.

§8 닮음 점수가 실제로 움직였다

55초 계속

그런데 이건 **해석의 근거**이고 **분류 성능이 좋아졌다는 근거가 아닙니다.**

> 무대
> "분산 축소 = 아리까리한 증례가 전형 쪽으로"까지 말하고, 대가는 10장에서 설명한다고 예고한다.

§9 혈관종처럼 보이는 HCC 4예

40초

혈관종처럼 보이는 HCC 4예를 실제로 넣어 봤습니다. 문헌에 보고된 고에코 HCC — 후방강화 동반, halo, 혈관종과 나란히 — 사람이 봐도 어려운 것들입니다. **세 출력 모두 4예 전부 HCC로 분류했습니다.**

다만 **proof-of-concept**입니다. n이 4이고, 출판 figure에서 온 저해상도·타 장비 영상이라 domain shift가 큽니다. **민감도 추정치로 읽으면 안 됩니다.**

§10 증분 이득은 없었다

55초

가장 중요한 슬라이드입니다.

테스트에서 틀린 1건은 실제 혈관종인데, confidence가 0.0014로 임계값 0.0011을 간신히 넘어 HCC로 판정됐습니다. 그런데 **HCC cosine도 0.0325, Δscore도 −0.8879**로 — **세 출력이 똑같이 틀렸습니다.** 혼동행렬이 출력마다 완전히 같습니다.

이유는 이렇습니다. SupCon은 코사인을 올리면서 **클래스 간격도 좁혔습니다.** Δscore 간격이 3.16에서 **2.29**로 줄었고, 이 1장은 혈관종 HCC-cosine 분포의 **최댓값**입니다. 얇아진 경계에서 딱 한 장이 넘어간 것입니다.

§10 증분 이득은 없었다

55초 계속

정리하면, **cosine과 Δscore가 confidence에 더한 진단 이득은 이 데이터에서 입증되지 않았습니다.** 저희는 이걸 **음성 결과로 보고**합니다.

> 무대
> 한 박자 쉬고 다음 장으로. 이 문장이 발표의 결론이다.

§11 Novelty와 한계

50초

남은 것은 — **한 모델에서 두 종류의 숫자를 동시에 낸다**는 것, **판독자가 이미 하는 "닮음" 판단을 숫자로 남긴다**는 것, 그리고 **SupCon이 미학습 HCC 94.7%의 닮음 점수를 전형 HCC 쪽으로 정렬한다**는 것입니다.

한계는 분명합니다. **단일기관이라 외부 검증이 없습니다. 천장효과 때문에 증분 이득을 측정할 수 없습니다. Δscore는 오히려 감소했고, 닮음 상승은 SupCon 목적함수의 귀결이지 임상 타당성의 독립 증거가 아닙니다.** 배경 간 정보가 없어 층화가 불가능하고 단축경로 학습 가능성도 배제할 수 없습니다.

§11 Novelty와 한계

50초 계속

닮음 점수를 왜 하나 더 만들었는지 — 한 문장으로는 **"판독자가 이미 하는 비교 판단을 숫자로 남겨, 나중에 검증할 수 있게"** 하려는 것입니다. 정의는 간단합니다. 병변의 128차원 임베딩과 학습 데이터에서 만든 전형 HCC 프로토타입의 **코사인 유사도 평균**이고, 같은 방식으로 혈관종 프로토타입 점수도 냅니다.

1에 가까우면 같은 방향, 0이면 직교 — 즉 "전형 HCC와 얼마나 같은 방향을 보는가"를 −1에서 1 사이로 남긴 값입니다. **소프트맥스 확률이 아니고, 보정된 확률도 아닙니다.**

지금 데이터로는 **증분 이득이 없습니다.** 그래서 이 지표의 값어치는 **추가 연구에서만** 정해집니다.

만약 후속 연구에서 닮음 점수가 분류 성능에 **유의하게 좋은 영향**을 준다면, 그때는 **혈관종으로 follow-up 하기로 한 케이스 안에 섞여 있을 수 있는 HCC를 구제**하는 데 쓸 수 있습니다 — 추적 관찰에서 놓치기 쉬운 비전형 HCC를, 전형 혈관종과의 닮음 거리로 한 번 더 걸러보는 방식입니다.

다만 이건 **가설**이고, 오늘 수치로는 아무것도 보장하지 않습니다.

다음 단계는 **다기관 외부 검증**, **판독자 대상 전향적 비교**, **AFP·조영증강 영상과의 비교**, 그리고 **닮음 점수가 실제로 구제하는지 보는 후속 코호트**입니다.

> Grad-CAM을 왜 안 넣었는지 물으면: 배경 간 라벨이 없으면 heatmap이 국소 병변을 보는 건지 배경을 보는 건지 구분할 수 없어 오히려 오해를 만들 수 있기 때문이라고 답한다.

§12 감사

20초

이상입니다. 오늘 말씀드린 것은 두 가지입니다. **닮음 점수라는 두 번째 숫자를 만들었다**는 것, 그리고 **그 숫자가 아직 임상적 이득을 입증하지 못했다**는 것.

그리고 마지막 장 QR은 **지금 이 자리에서 직접 돌려볼 수 있는 웹 데모**입니다. 설치도 로그인도 필요 없고, 사진은 기기 밖으로 나가지 않습니다. HCC와 혈관종 예시가 각각 네 개씩 들어 있으니 눌러보시면 됩니다. 다만 **화살표·캘리퍼·환자정보가 섞이거나 병변만 잘라낸 사진은 결과를 믿을 수 없습니다** — 영상 전체를 넣어야 합니다.

질문과 토론을 환영합니다. 감사합니다.