

B-MODE 초음파 · 임상 의사결정지원 · 탐색적 연구

B-mode 복부 초음파에서 간세포암과 간혈관종
감별을 위한
딥러닝 모델의 Confidence Score와 임베딩 기반
유사도 점수

단일기관 공개 데이터셋을 이용한 탐색적 연구

HCC vs Hemangioma

CE + Supervised Contrastive Learning

Hybrid Vision Transformer

연구 배경

우연히 발견된 간 결절 — 혈관종과 간암의 감별은 여전히 어렵다

- B-mode 초음파는 가장 접근성이 높은 간 병변 평가·감시 도구 — 비침습적, 저비용, 반복 가능
- 그러나 조기 병변에 대한 민감도가 낮고 검사자 의존성이 큼
- 감별의 어려움은 두 클래스 내부의 표현형 다양성(전형 ↔ 비전형)에서 기인

47%

초음파 단독 조기 HCC 민감도

63%

AFP 병용 시

병변의 suspiciousness를 연속형으로 정량화하는 보조 지표가 부재한 것이 이 한계의 일부이다.

연구 배경

두 질환 모두 '전형-비전형' 스펙트럼이 넓고, 기존 AI는 이를 단일 확률로 압축한다

HCC

전체의 10-15%가 비전형 소견

고분화 HCC가 고에코성 혈관종 패턴을 모사

혈관종

비전형 혈관종이 악성을 모사

저에코 테두리 · 이질적 에코 · 경계 불분명

기존 딥러닝의 구조적 한계 — 단일 softmax 출력


- 별도 보정 없이는 실제 확률을 반영하지 않는 과잉 확신
- "전형 HCC와 얼마나 닮았는가"라는 비전형성 정보가 소실 — 추가 검사가 필요한 병변의 triage 부재

딥러닝 기초 ①


임베딩 — 영상을 "딤음의 좌표"로 요약한다

- 영상 $\rightarrow$ 신경망 $\rightarrow$ 고차원 숫자 벡터로 압축
- 비슷한 병변은 가까이, 다른 병변은 멀리
- 벡터 사이의 각도(cosine) = 의미적 유사도

각 클래스의 "전형적인 모습"에 해당하는 대표 벡터를 prototype이라고 한다. cosine similarity는 병변이 이 prototype에 얼마나 닮았는지를 연속값으로 준다.



Hybrid ViT — CNN의 국소 특징 + Transformer의 전역 문맥



하나의 CLS 임베딩에서 성격이 다른 두 종류의 점수를 동시에 산출하는 이중 출력 구조가 본 연구의 핵심이다.

대상 및 방법

데이터 — SMC-LUD clean subset

744

명 환자

2,656

장 영상

- 병리확진 **HCC 1,389장** · 영상진단 **혈관종 1,267장**
- 환자 단위 분할(원저 70:20:10 준용)로 개발-평가 간 누출 차단
- caliper artifact·poor echo window 제외한 clean subset

원 데이터셋 SMC-LUD 1,021명 5,385장 (Tak J, et al. Sci Data 2026) 중 품질 기준 통과 clean subset

Train / Val / Test 분할

	환자	영상	Train	Val	Test
혈관종	323	1,267	886	253	128
HCC	421	1,389	972	277	140
합계	744	2,656	1,858	530	268

환자당 평균 3.57장 — 1:1 매칭이 아님(한계에서 재논의).

CE + SupCon, 그리고 2 backbone × 3 학습 모드 = 6개 조건

CE only

교차 엔트로피로 분류 경계 형성. 임베딩 구조는 학습 목적이 아님.

CE + SupCon

같은 클래스는 가까이, 다른 클래스는 멀리
→ 임베딩에 응집성·분리성 부여.

NNCLR 2단계

레이블 없는 SSL 사전학습 → CE+SupCon
미세조정. 사전학습의 추가 이득 검증.

총 손실 = 분류 손실 + 유사도 정렬 손실

$$\mathcal{L} = \mathcal{L}_{\text{CE}} + \lambda \mathcal{L}_{\text{SupCon}}, \quad \mathcal{L}_{\text{SupCon}} = \sum_i \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(\mathbf{z}_i \cdot \mathbf{z}_p / \tau)}{\sum_{a \in A(i)} \exp(\mathbf{z}_i \cdot \mathbf{z}_a / \tau)}$$

임계값은 검증 세트에서만 Youden's J로 결정 후 테스트 세트에 고정 적용. 이항 성능 지표는 Clopper-Pearson 95% CI. ($P(i)$: 동일 클래스 집합 · τ : temperature · λ : 가중치)

이중 출력 표지자 정의

세 가지 출력의 임상적 의미

①

Confidence score

HCC softmax 값. 확률이 아닌 결정 강도 (decision strength)로 정의

②

HCC Cosine score

임베딩과 HCC prototype(k-means k=4) 평균 유사도 = "전형 HCC와의 닮은 정도"

③

Δ score

HCC 닮음 - 혈관종 닮음 = 두 경쟁 클래스 간 상대적 위치

임상 판독은 이진 결정이 아니라 "전형 HCC와 얼마나 닮았는가"를 평가하는 유사성 기반 추론이다. 본 연구는 이 추론을 임베딩 공간의 cosine 유사도로 정량화하고자 하였다 — 단, 표지자의 추가적 임상 이득은 본 연구에서 입증되지 않았으며 후속 검증이 필요하다.

결과 ① 주력 모델 성능

테스트 세트 — 위음성 0건, 위양성 1건

1.000

AUROC (val-test)

100%

테스트 민감도

99.2%




테스트 특이도

99.6%

테스트 정확도

Confidence Score 성능 (EfficientNetV2B0 + CE+SupCon)

지표	Validation	Test
AUROC	1.000	1.000
Accuracy (%)	100.00	99.63
Sensitivity (%)	100.00	100.00
Specificity (%)	100.00	99.22
F1	1.0000	0.9964
TP / FP / FN / TN	277/0/0/253	140/1/0/127



① Confidence
세 출력이 모두 동일하게 1건만 오분류 — cosine 표지자는 주 출력과 동등한 분류를 수행.

결과 ② 이중 출력 비열등성

세 출력 모두 AUROC 1.000 — 단, 천장효과를 함께 보아야 한다





Figure 3 (Test) · Table 4. ns: not significant ($p>0.05$).

출력	AUROC	DeLong p
① Confidence Score	1.000	— (기준)
② HCC Cosine (mean)	1.000	1.000 (ns)
③ Δ score (mean)	1.000	1.000 (ns)
② HCC Cosine (k=4)	1.000	1.000 (ns)
③ Δ score (k=4)	1.000	1.000 (ns)

천장효과 주의 ▶ AUROC가 1.000에 도달하면 DeLong 검정력이 제한되어 비열등성을 단정할 수 없다. 5개 출력이 동일한 1건만 오분류하여 cosine 표지자의 단독 증분 이득은 입증되지 않았다.

SupCon은 미학습 증례에서 cosine score를 prototype 쪽으로 응집시켰다



True HCC (val+test, n=417)

True Hemangioma (val+test, n=381)

True HCC 중앙값 0.882 → 0.970 · 분산 -60.7%

True Hemangioma 중앙값 0.955 → 0.985 · 분산 -98.7%

Wilcoxon signed-rank · Pitman-Morgan test p < 0.001. CE 단독 대비 SupCon 적용 시 미학습 증례 점수가 우측 이동·분산 축소 — SupCon을 추가적 정규화 요소로서 해석할 여지를 제공한다(정확도가 아닌 임베딩 구조에 대한 효과).

결과 ④ ABLATION · SSL 한계

SSL 사전학습(NNCLR 2단계)은 추가 이득을 주지 못했다

Table 2 — Validation, Confidence score

Backbone	학습 모드	AUROC
ResNet50V2	CE only	1.0000
EfficientNet	CE only	0.9999
EfficientNet	CE + SupCon	1.0000
ResNet50V2	NNCLR 2단계	0.9994
EfficientNet	NNCLR 2단계	0.9986

Table 4B — Test, HCC cosine AUROC

모델	Confidence	HCC cosine
Eff · CE+SupCon	1.000	1.000
Eff · NNCLR	1.000	0.893
Res · NNCLR	0.999	0.068

- CE·CE+SupCon 조건에서 AUROC 1.000 유지
- NNCLR 2단계는 분류 성능 열등, cosine 표지자는 무작위 수준으로 붕괴(0.068)

소규모 레이블 데이터셋에서는 SSL 사전학습의 계산 비용이 정당화되지 않을 수 있음을 시사한다(탐색적 소견).

임상적 의미와 남은 과제

의미 (Exploratory)

- 출력 해석론의 전환 — softmax를 확률이 아닌 결정 강도로 재정의
- 유사성 기반 추론의 정량화 — HCC cosine· Δ score 표지자 후보 제안(임상 이득은 미입증)
- SupCon의 추가적 정규화 가능성 — 임베딩 응집·분산 축소

한계

- 단일기관 공개 데이터셋 — 외부 검증 부재
- 배경 간질환(간경변·지방간·AFP) 정보 부재
- 영상 단위 CI — 환자 내 상관성 미보정(1:1 매칭 아님)
- spectrum·selection bias, AUROC 1.000 천장효과

본 연구는 B-mode 초음파에서 임상적의 유사성 기반 추론에 대응하는 연속형 표지자 후보(confidence / HCC cosine / Δ score)를 제안한 탐색적 연구이다.

향후 과제: 외부 다기관 검증 · AFP 등과의 독립 기여 평가 · SSL 민감도 분석 · Grad-CAM 등 영상 설명.

감사합니다 · 질문과 토론을 환영합니다 — 김현수 · 예수병원 가정의학과

