B-MODE 복부 초음파 · 발견된 국소 병변의 감별

AI가 예측한 간암, 확률을 넘어 유사도 점수까지

B-mode 초음파에서 발견된 국소 병변의 간세포암–간혈관종 감별을 위한 이중 출력 지표(Confidence · HCC cosine · Δscore)의 방법론적 타당성: 단일기관 공개 데이터셋을 이용한 탐색적 연구

HCC vs Hemangioma | CE + SupCon | Hybrid ViT | 탐색적 · 단일기관

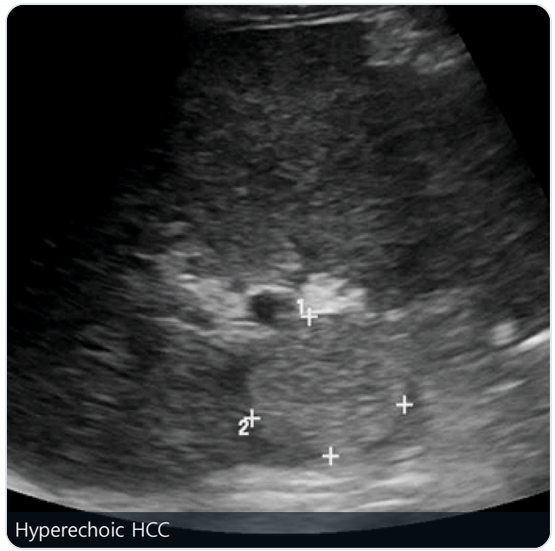
1.000	99.2%	0	2,656
AUROC (내부검증)	특이도 · Test	HCC 위음성	영상(clean)

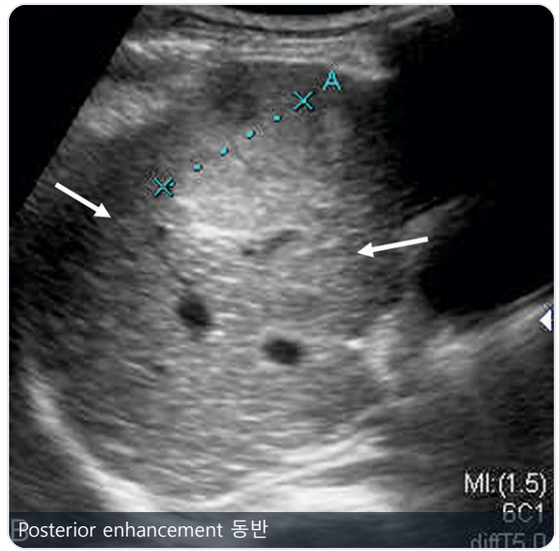
예수병원 가정의학과 R3 김현수

임상 배경 ① · 왜 어려운가

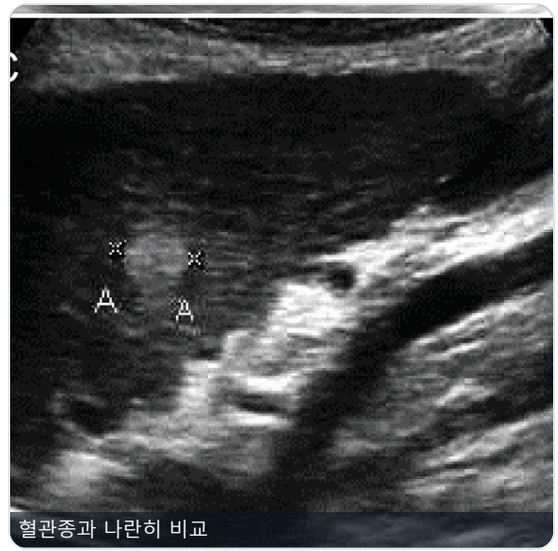
What is your diagnosis?


고에코 HCC


Hyperechoic HCC



Posterior enhancement 동반


혈관종과 나란히 비교

모두 간암(HCC) — 혈관종처럼 보이지만 실제로는 HCC

혈관종의 전형은 고에코·경계 명확·후방음영 증가다. 그러나 HCC의 10–15%는 비전형 소견이고 고분화 HCC가 고에코 혈관종 패턴을 모사할 수 있다 [5]. 반대로 비전형 혈관종은 악성을 모사한다 [6,7].

임상 배경 ② · 연구 범위

이미 발견된 국소 병변에서 — HCC인가, 혈관종인가

1. 범위를 좁혀 둔다

이 연구는 간암 감시(surveillance)나 선별 검사가 아니다. 초음파에서 이미 발견된 국소 병변을 HCC와 혈관종으로 가르는 감별 진단 보조를 다룬다. 감시 민감도 향상은 주장하지 않는다.

"감시 민감도 47%"는 배경 설명이며 이 연구의 성능 근거가 아니다

2. B-mode 단독은 부족하다

경력 15년 판독자 236명의 B-mode 단독 판독 — 정확도 76.0% · 민감도 76.1% · 특이도 76.9%

비조영 US 딥러닝 meta-analysis: 민감도 81.7% · 특이도 84.8% → 개선 여지가 남아 있다

3. 두 클래스 안쪽이 넓다

HCC·혈관종 모두 전형–비전형 스펙트럼을 가진다. 기존 AI는 이 스펙트럼을 단일 이진 출력으로 압축해, 병변이 전형 군집의 핵심부인지 주변부인지를 알려주지 않는다.

판독자는 "전형 HCC와 얼마나 닮았는가"로 판단한다 — LI-RADS 계층 구조가 그 예

그래서 우리는 분류 성능이 아니라, 판독자가 이미 하는 "닮음" 판단을 숫자로 남기는 지표를 만들고 그 방법론적 타당성만 평가한다.

Minami 2023 [5] · Chou 2017 [6] · Sirli 2015 [7] · Yang 2020 [9] · Campello 2023 [18]

방법 ① · 대상과 데이터

대상 환자와 데이터 — SMC-LUD clean subset (n=744)

	환자	영상	Train	Val	Test
혈관종	323	1,267	886	253	128
HCC	421	1,389	972	277	140
합계	**744**	**2,656**	**1,858**	**530**	**268**

- 제외 기준은 caliper 등 주석 인공음영이 없는 clean 영상 (원저 기준)
- 분할은 원저가 보고한 환자 단위 분할을 그대로 사용했다
- 단, 공개 파일에 환자 ID 매핑이 없어 우리가 재검증하지는 못했다 — 근접 중복 프레임도 독립 감사 불가
- 임계값은 검증 세트에서만 Youden's J로 정하고 테스트에 고정

환자 특성 — 전체 코호트(n=1,021) 기준. clean subset(744명)의 특성은 별도로 제공되지 않았다.

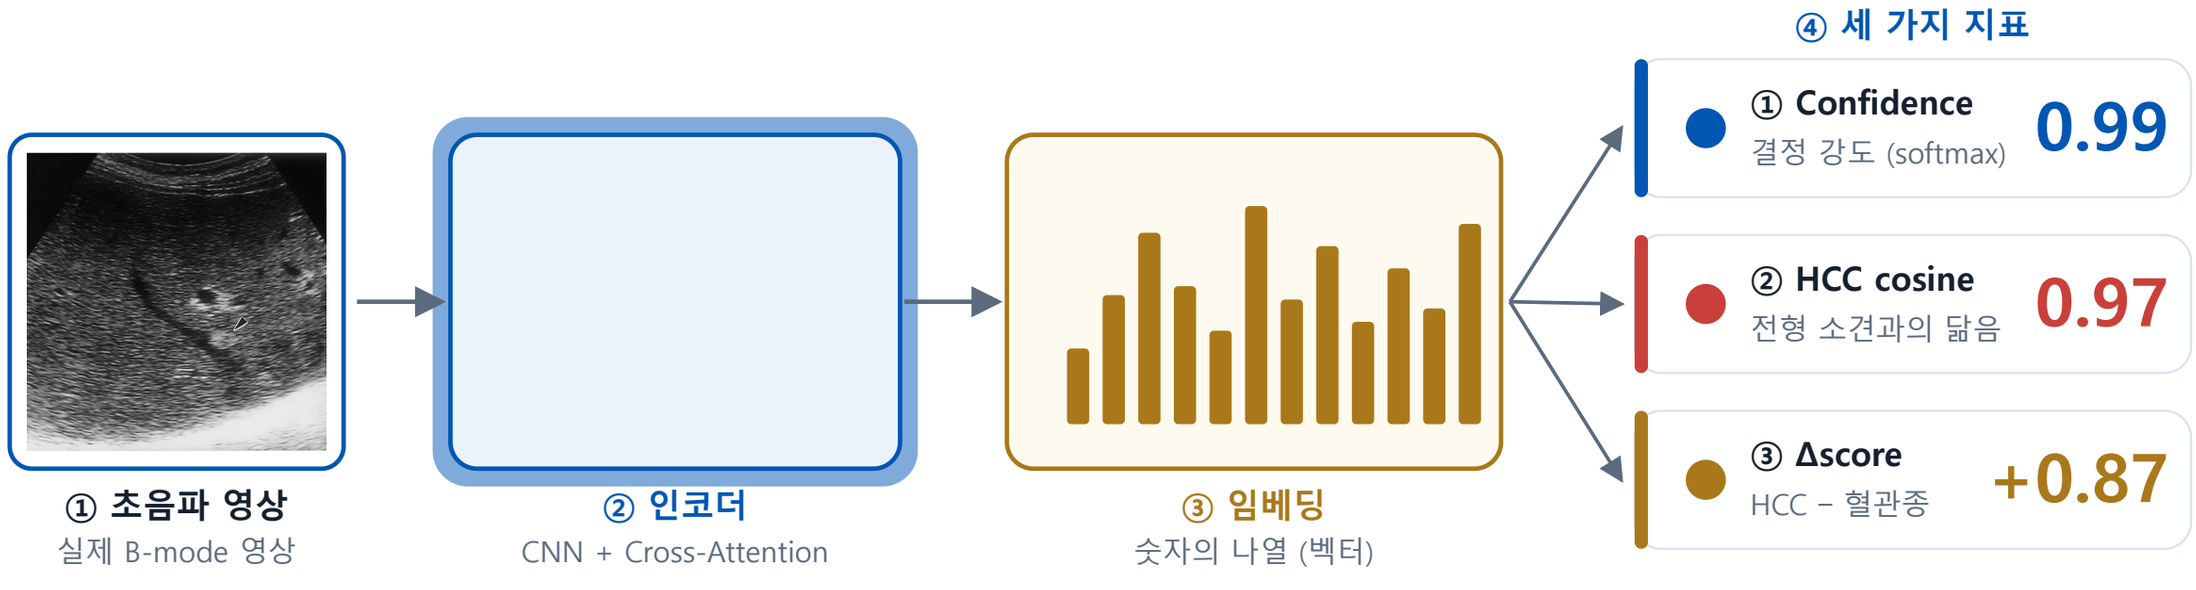
특성	HCC	혈관종
나이 (평균±SD)	66.7 ± 11.0	55.5 ± 12.8
남성	81.8%	41.3%
병변 최대지름 (중앙값)	2.90 cm	— (미제공)
진단 근거	병리확진	영상 판독

- 참조표준이 비대칭: HCC는 병리확진, 혈관종은 영상 판독 → 혈관종 라벨 오류 가능성
- 두 군의 나이·성별 구성이 크게 다르다 — 배경 간질환 분포가 다를 것으로 예상되나 정보가 없다
- 원저의 대표영상 선별과 clean subset 자체가 선택 편향 원천일 수 있다

SMC-LUD(공개 데이터셋)[12] clean subset. HCC와 혈관종 비율은 세트 간 균형 유지(약 52% vs 48%).

방법 ② · 우리가 내는 것

확률 하나가 아니라 — "전형 소견과 얼마나 닮았는가"



① Confidence

HCC 클래스의 softmax 값. 보정된 사후확률이 아니므로 이 연구에서는 확률이 아니라 결정 강도로 부른다.

② HCC cosine

훈련 세트 HCC 임베딩의 평균 위치(prototype)와 병변 임베딩의 각도(cosine). "전형 HCC와 얼마나 닮았는가". k-means(k=4) 다중 prototype은 보완 민감도 분석.

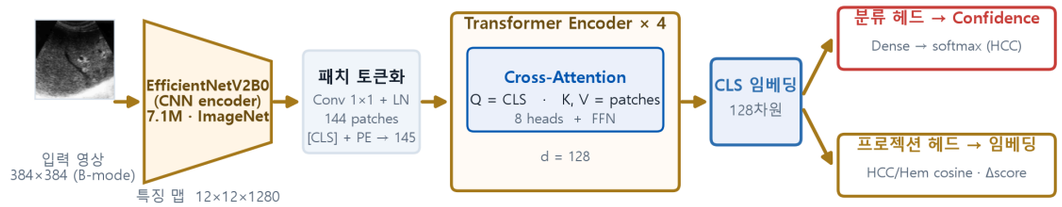
③ Δscore

HCC cosine − 혈관종 cosine. 두 클래스 중 어느 쪽에 더 가까운가만 말하는 상대 위치 지표다. 이 지표의 검증 결과는 슬라이드 10에서 정직하게 다룬다.

판독자가 전형 소견과 비교하며 위험도를 나누는 사고(LI-RADS 계층)와 구조적으로 대응한다고 본다 — 임상적 유용성을 주장하는 근거는 아니다.

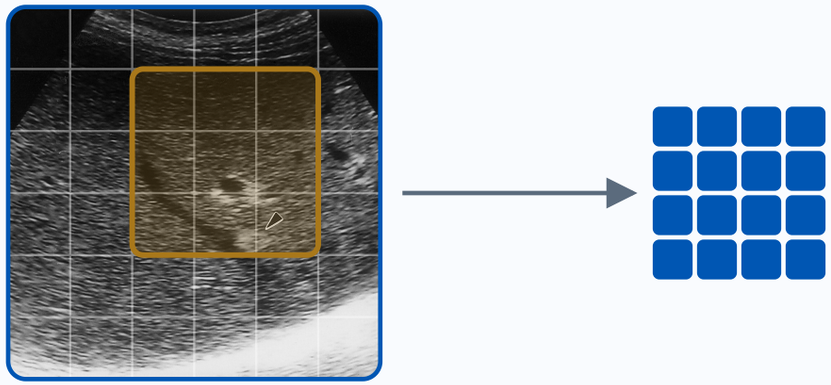
인코더 내부 — 필터가 훑고, CLS가 패치를 본다

Hybrid Vision Transformer — EfficientNetV2B0 + Cross-Attention



① 합성곱 — 필터가 영상을 훑는다

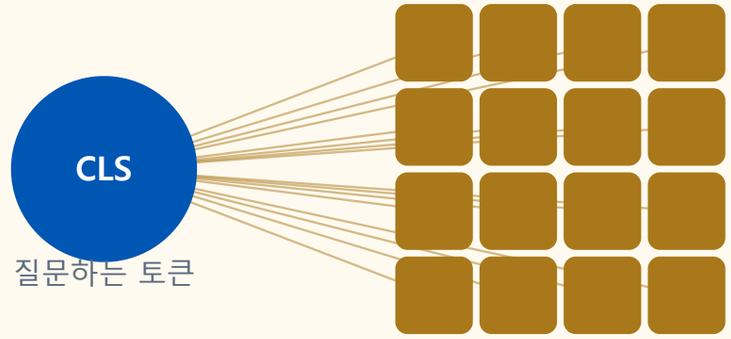
노란 창 = 3×3 합성곱 필터



입력 영상 · 6×6 타일 특징 맵 · 4×4

한 칸씩 미끄러지며 각 위치의 국소 특징을 뽑는다

② Cross-Attention — CLS가 패치를 본다



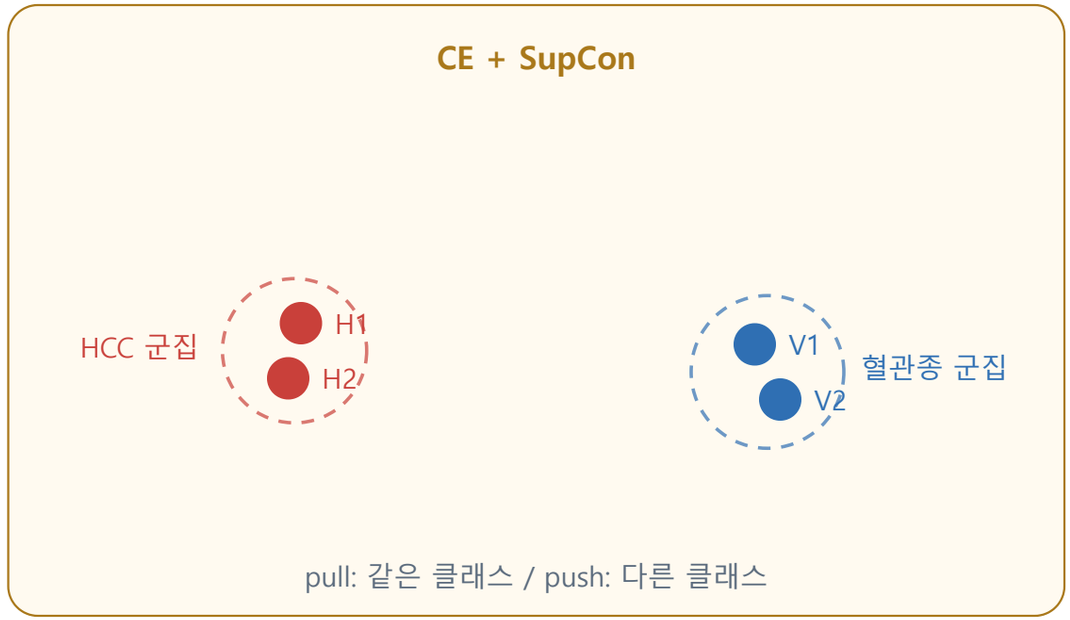
패치 토큰 4×4 (실제 7×7 = 49개)

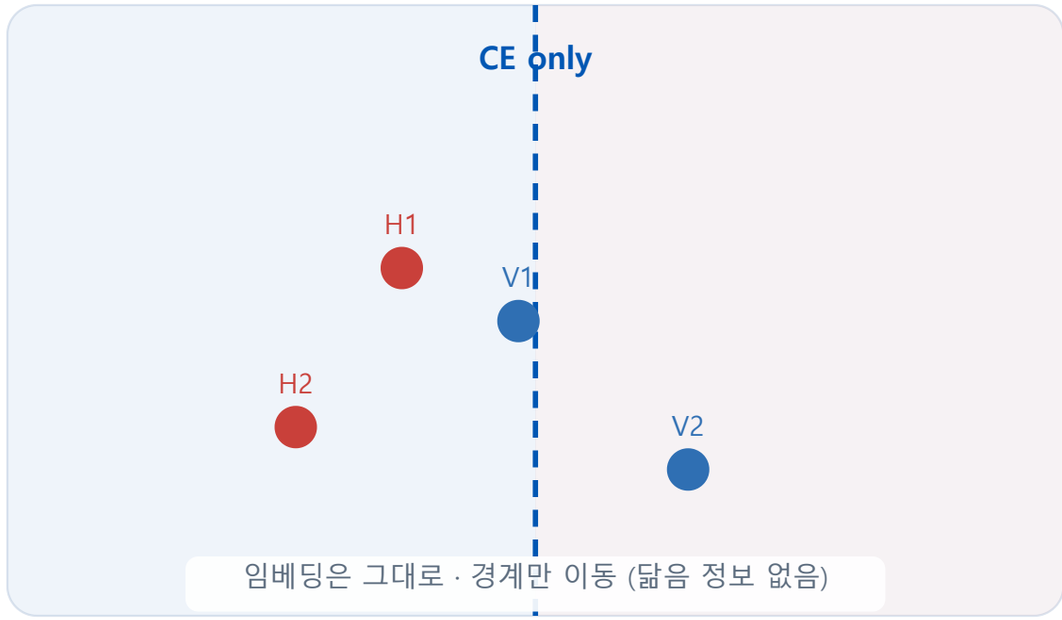
패치마다 가중치를 주며 훑고, 하나의 CLS 임베딩에 종합한다

흐름: 384×384×3 → CNN 특징 7×7×1280 → 패치 토큰 49개 → CLS 384차원. 세 지표는 모두 이 CLS 임베딩 하나에서 나온다. EfficientNetV2B0(7.1M)를 쓴 이유는 ResNet50V2(23.6M)와 동등한 AUROC를 더 가벼운 모델로 냈기 때문이다.

방법 ④ · 학습 전략

SupCon은 분류 성능이 아니라 임베딩 기하를 바꾼다





0.882 → 0.970

true HCC(n=417)의 HCC cosine 중앙값 · 대응분석 p<0.001 (증가)

+1.508 → +1.076

같은 케이스의 Δscore 중앙값 · 대응분석 p<0.001 (오히려 감소)

CE only도 천장

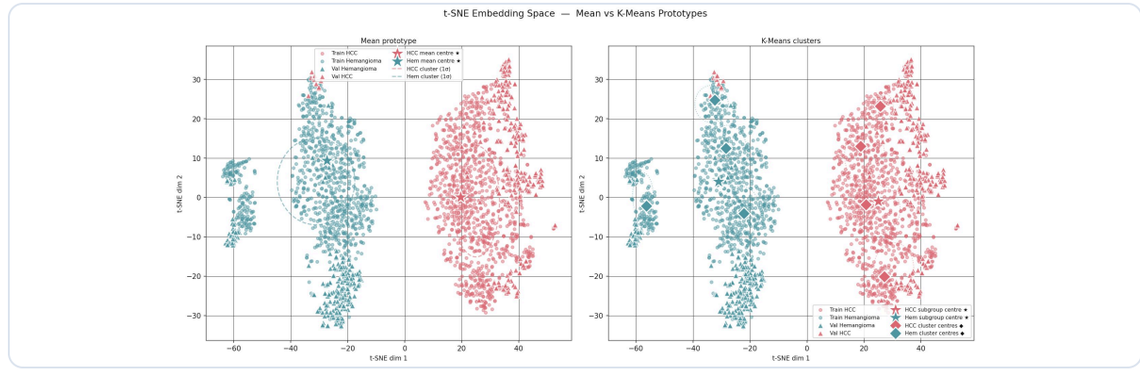
CE 단독에서도 cosine·Δ AUROC 1.000에 근접 → "SupCon 필수"는 주장하지 않는다

SupCon은 같은 클래스를 모으고 HCC cosine을 올린다. 그러나 Δscore는 유의하게 낮아졌다 — 즉 이 연구는 Δscore의 타당성을 입증하지 못했다. SupCon의 남는 기여는 분류 성능이 아니라 표상 기하에 대한 것이다.

결과 ① 주력 모델 성능

테스트 세트 — 위음성 0건, 위양성 1건

지표 (confidence 기준)	검증 n=530	테스트 n=268
AUROC	1.000	1.000
민감도 (95% CI)	100.0% [98.7–100]	100.0% [97.4–100]
특이도 (95% CI)	100.0% [98.6–100]	99.2% [95.7–100]
정확도 (95% CI)	100.0% [99.3–100]	99.63% [97.9–100]
TP / FP / FN / TN	**277 / 0 / 0 / 253**	**140 / 1 / 0 / 127**



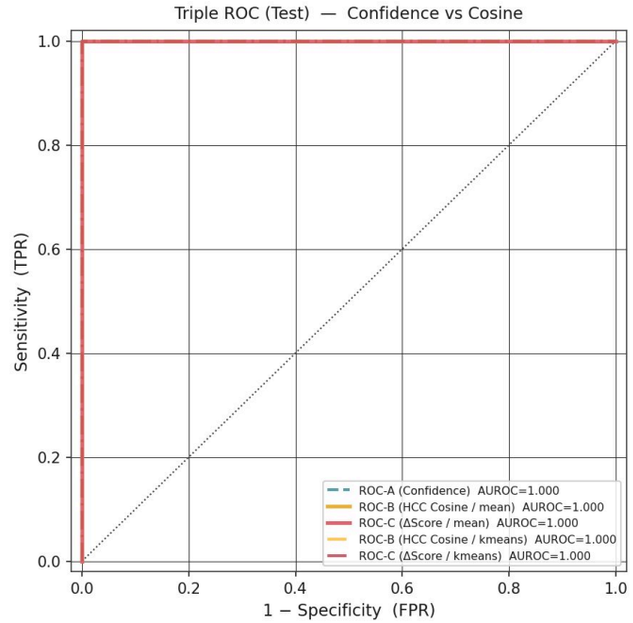
임베딩 공간 시각화(t-SNE) — 두 클래스 클러스터가 분리된다. 그림 자체는 모델의 변별력 근거가 아니다.

- 검증 세트는 출력에 따라 다르다: confidence·Δscore 100.0%, HCC cosine 99.81% (TP276/FN1)
- 신뢰구간은 영상 단위(image-level) Clopper-Pearson이다 — 환자 내 상관 때문에 실제보다 좁게 추정됐을 수 있다

세 출력이 테스트에서 정확히 같은 1장(실제 혈관종)을 위양성으로 판정했다 — 즉 cosine 지표의 증분 이득은 입증되지 않았다.

결과 ② 세 출력 비교

세 출력 모두 AUROC 1.000 — 이 숫자는 우열을 말해주지 않는다



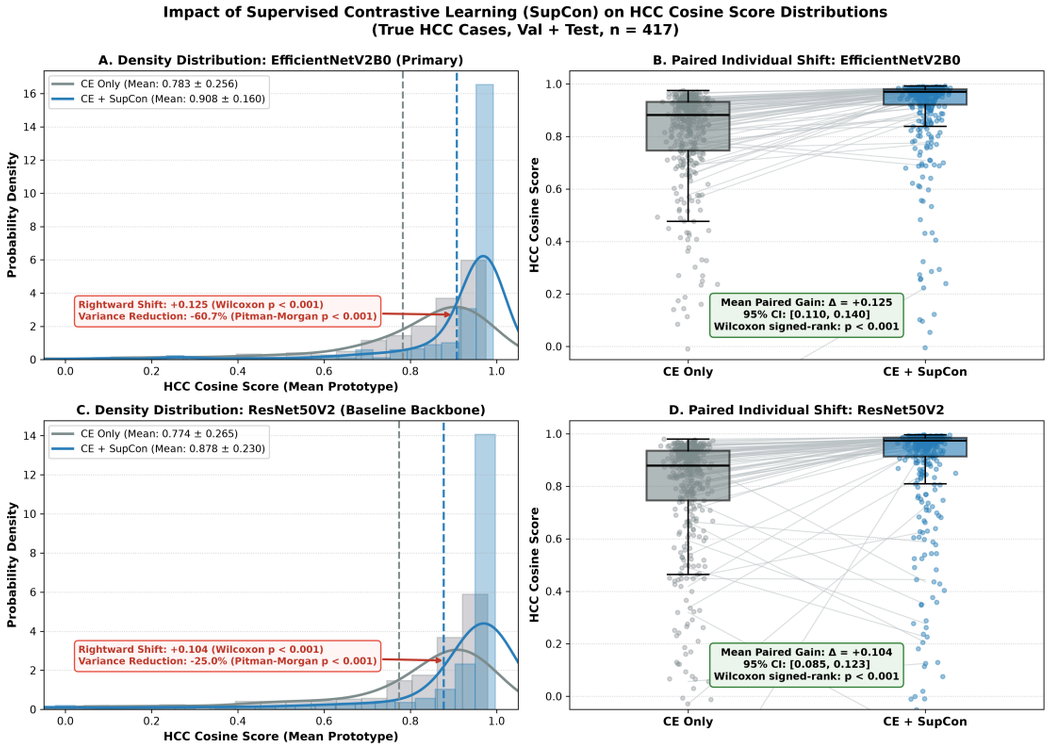
출력	AUROC (Test)	Test 오류 (FP/FN)
① Confidence	1.000	1 / 0
② HCC cosine (mean)	1.000	1 / 0
③ Δscore (mean)	1.000	1 / 0
②③ k-means k=4	1.000	1 / 0

천장효과 ▸ AUROC가 모두 1.000이면 DeLong 검정은 실질적 비교 정보를 주지 못한다. 이 연구는 비열등성·동등성 주장을 하지 않는다. 5개 출력이 같은 1장을 오분류했으므로 증분 이득도 미입증이다.

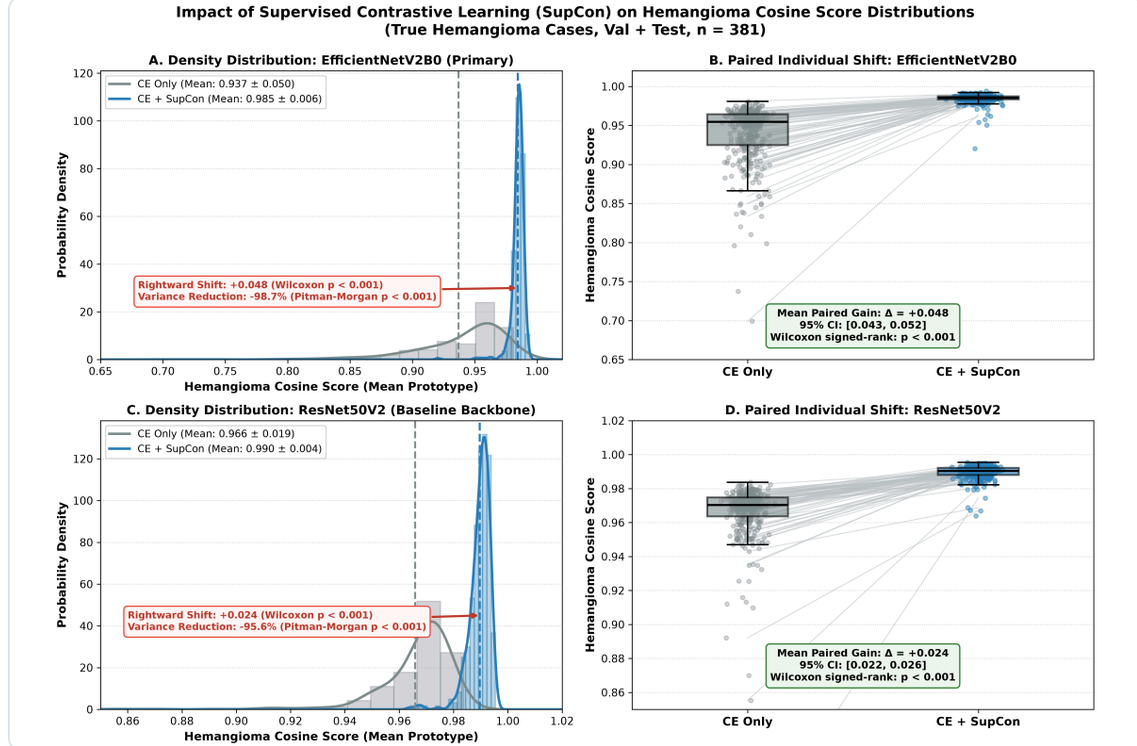
- 따라서 주장은 "더 잘 맞힌다"가 아니라 "같은 모델에서 판독 가능한 두 번째 숫자를 함께 낼 수 있다"까지다

결과 ③ · SUPCON 전후 분포

닮음 점수의 분포는 바뀐다 — 단, 모든 지표가 같은 방향은 아니다



true HCC (n=417) · HCC cosine · A 밀도분포 · B 쌍별 이동



true 혈관종 (n=381) · hemangioma cosine · A 밀도분포 · B 쌍별 이동

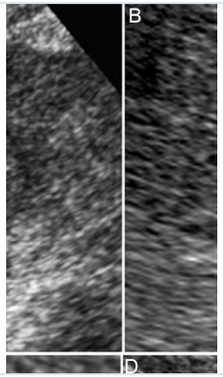
- HCC cosine는 상승: 중앙값 0.882 → 0.970, 분산 −60.7% (대응분석 p<0.001) — 전형 HCC 쪽으로 정렬됐다
- 혈관종 cosine도 상승: 0.955 → 0.985, 분산 −98.7% — 같은 방향의 변화
- 그러나 Δscore는 유의하게 감소했다 (+1.508 → +1.076, p<0.001). 즉 Δscore의 임상적 타당성은 이 데이터로 지지되지 않는다
- 이 분포 변화는 해석의 근거이지 분류 성능 개선의 근거가 아니다

전부 true HCC(Val+Test) · true 혈관종 기준의 기술적 분포 비교다. 그림의 분산 감소율은 각 그림 캡션 값과 일치한다.

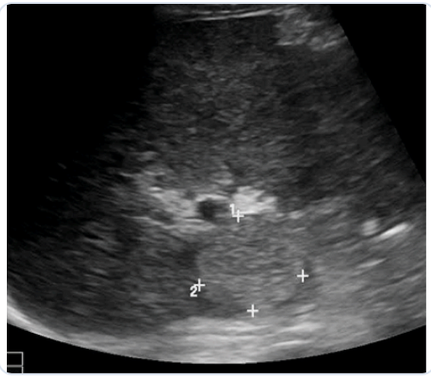
결과 ④ · 탐색적 점검

혈관종처럼 보이는 HCC — 문헌 증례로 본 탐색적 점검

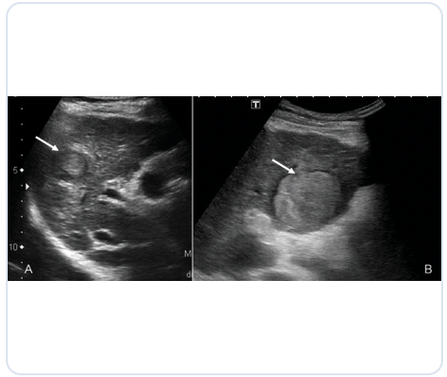
초음파에서 혈관종과 구별이 어렵다고 문헌에 보고된 고에코 HCC 5예(공개 figure에서 수집)를 넣어 보았다. 외부 검증이 아니다.



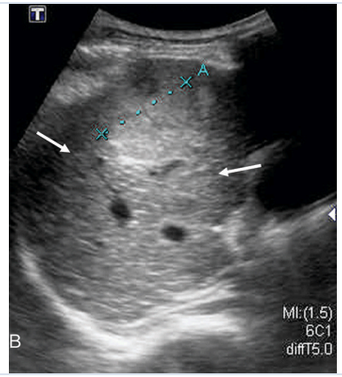
① <3 cm 균질 고에코 HCC
JCTH 2024 Fig 1B (CC BY-NC 4.0)



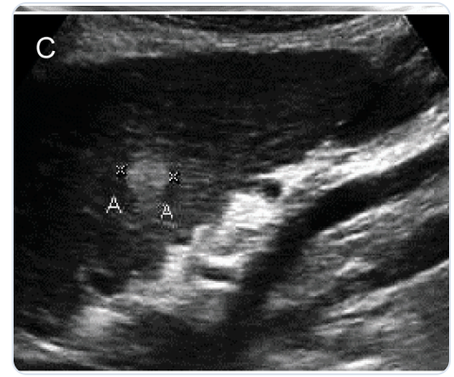
② 고에코 HCC 결절
J Med Assoc Thai 2013 Fig 4



③ halo + 후방강화 동반
동일 논문 Fig 10



④ 후방강화 동반 고에코 HCC
동일 논문 Fig 11B



⑤ 혈관종과 나란히 비교
동일 논문 Fig 12C

모델 출력 — 5예 모두 HCC로 분류

- Confidence 5/5 (P(HCC) 0.989–1.000)
- HCC cosine 5/5 (0.849–0.989) · Δscore 5/5 (0.651–1.228)

그래서 무엇을 말할 수 있나

- n=5, 출판 figure 유래 저해상도·다른 장비 → domain shift 큼
- 파이프라인 동결 전의 평가다. "외부 검증"이 아니라 탐색적 sanity check이며, 민감도 추정치로 읽으면 안 된다
- 출처 표기 필요: JCTH 2024 (CC BY-NC 4.0) · J Med Assoc Thai 2013

고찰 ① · 실패와 한계

위양성 1건과, 이 연구가 아직 말할 수 없는 것

테스트 오분류 1건의 정체

항목	값
실제 진단	혈관종
confidence (임계값 0.0011)	0.0014 → HCC로 오판
혈관종 cosine	0.920 (혈관종 쪽)
Δscore	−0.888 → 역시 HCC로 오판

세 출력이 같은 방향으로 함께 틀렸다. cosine이 confidence를 구제한 사례는 이 데이터에 없다 — 이것이 증분 이득 미입증의 실체다.

한계 — 임상 적용 전에 넘어야 할 것

- 참조표준 비대칭: HCC는 병리확진, 혈관종은 영상 판독 → 혈관종 라벨 오류 가능
- 선택 편향: 원저의 대표영상 선별 + 정제된 clean subset → 높은 정확도가 데이터 조건에서 기인했을 수 있음
- 단일기관·단일 데이터셋 → 일반화·배포 주장을 하지 않는다. 장비 게인·탐촉자·검사자 변동 미평가
- 환자 ID 없음 → 환자 단위 집계·cluster bootstrap 불가, CI는 image-level이라 좁게 추정됐을 수 있고, 근접 중복 프레임 감사도 불가
- 배경 간 층화 미시행(B/C형 간염·간경변·지방간 정보 없음) → 모델이 배경 간 실질을 shortcut으로 학습했을 가능성을 배제할 수 없다
- Grad-CAM 미제시: 배경 간 라벨이 없어 heatmap의 국소병변/배경 반응을 구분할 수 없어 오히려 오용 위험이 크다
- 천장효과: 출력 간 우열 구분 불가 · Δscore는 SupCon에서 감소 → Δscore 타당성 지지 근거 없음
- 미수행: AFP 대비 증분 기여, decision curve analysis(net benefit), 부트스트랩 CI, SSL 하이퍼파라미터 민감도

정리: 이 연구는 "이런 지표를 산출할 수 있다"는 방법론적 실현과 정직한 음성 결과를 보고한 탐색적 연구다. 임상적 유용성은 다기관 외부 검증과 판독자 대상 연구로만 판단될 수 있다.

고찰 ② · 주장의 경계

말하는 것과, 말하지 않는 것

말하는 것

- 같은 모델 하나에서 confidence와 임베딩 유사도(HCC cosine·Δscore)를 동시에 산출하는 방법을 구현했다
- SupCon 학습이 HCC cosine 분포를 전형 HCC 쪽으로 정렬한다 ($p < 0.001$)
- 공개 데이터로 모든 수치를 재현 가능하게 산출했다
- 증분 이득이 없다는 결과를 포함해 정직하게 보고했다

말하지 않는 것

- 분류 성능이 우월하다 — 세 출력 AUROC가 같은 천장이라 비교 자체가 불가
- 감시·선별에 쓰일 수 있다 — 범위는 이미 발견된 병변의 감별 보조
- 일반화·즉시 적용 가능 — 단일기관, 외부 검증 없음
- 임상적 이득·순편익 — decision curve analysis도 하지 않았다
- Δscore의 임상적 타당성 — SupCon에서 오히려 감소했다

다음 단계는 이 순서다: ① 다기관·타 장비 외부 검증 → ② 조영증강 CT/MRI·CEUS 및 AFP와의 비교 → ③ 판독자 대상 전향적 비교로 실제 판단 변화와 환자 결과 확인 → ④ decision curve analysis로 순편익 평가.

모든 수치는 per-case 점수 CSV에서 재계산했다 (scratch/verify_v2_numbers.py).

THANK YOU

감사합니다

질문과 토론을 환영합니다.

예수병원 가정의학과 R3 김현수