발표대본_v5.md

발표 대본 — v5 (12장, 발표 8분 + 질의 2분)

> 발표: 대한가정의학회(KFM) 2026년도 추계학술대회 · 2026.10.24 발표자: 예수병원 가정의학과 R3 김현수 자료: `hcc_dual_output_talk_v4.html` (학술지 판면 디자인, 12장) **발표 8분(480초) + 질의 2분(120초)** 기준. 공학적 내용(§5·§6·§8)은 결론만 말하고, 자세한 구조·학습 설정·분포 통계는 **"질의 시간에 설명드리겠습니다"** 로 넘긴다. 시간이 밀리면 **§8 → §6 둘째 문단 → §11 후반부** 순서로 뺀다. 남는 시간은 장 전환용이다.

v5 구성 (v4 대비)

- 10분 → **8분 발표 + 2분 질의**로 재편. 12장 구성은 그대로 두고 말하는 양만 줄였다.
- **§5 인코더 15초, §6 SupCon 30초, §8 분포 25초** — 공학 3개 장을 합쳐 70초로 압축(이전 155초).
- 공학 내용은 **한 문장 결론 + 질의 안내**로 끝낸다. 수치·구조·검정 이름은 슬라이드에만 남긴다.
- 임상 축(§2·§3·§4·§7·§9·§10·§11)은 유지하고, §7에 시간을 더 줬다(70초).
- 주 분석 0.50, 닮음 지표는 탐색적, 컷오프·등가 구간은 검증 세트 유도 — v4와 동일.

시간 배분

#	슬라이드 (eyebrow)	배분
1	표지	15초
2	What is your diagnosis? (임상 배경)	50초
3	그 76%는 어디서 온 숫자인가 (근거)	35초

#	슬라이드 (eyebrow)	배분
4	확률이 아니라 "닮음" (방법)	50초
5	인코더 내부 (방법)	15초
6	SupCon은 임베딩의 모양을 바꾼다 (방법)	30초
7	확률 0.5는 위음성 6, 닮음 지표는 위양성 1 (결과)	70초
8	닮음 점수가 실제로 움직였다 (결과)	25초
9	혈관종처럼 보이는 HCC 4예 (결과)	40초
10	차이는 유의하지 않다 — 실패 지점이 다르다 (고찰 ①)	55초
11	Novelty와 한계 (고찰 ②)	50초
12	감사	10초
	합계	**7분 25초** (+ 전환 35초 = 8분)

1. 표지 — 15초

안녕하십니까. 예수병원 가정의학과 R3 김현수입니다. B-mode 복부 초음파에서 간암과 간혈관종을 감별할 때 쓰는 **확률 하나에 "유사도 점수"라는 두 번째 숫자를 더한** 탐색적 연구입니다. 8분으로 줄여서 **임상 결론 중심**으로 말씀드리고, **공학적 세부는 질의 시간에** 답하겠습니다.

> 무대: 제목·소속만 짚고 넘어간다. 8분이라는 말로 기대치를 먼저 맞춘다.

---

2. What is your diagnosis? — 50초

네 장 모두 B-mode 복부 초음파입니다. 혈관종의 전형은 고에코, 경계 명확, 후방음영 증가인데 — **(클릭)** — 네 장 모두 **간암**입니다. 고분화 HCC가 혈관종의 전형을 그대로 흉내 냅니다.

얼마나 어려운지 숫자 하나로 보겠습니다. 2020년 다기관 연구에서, 15년 경력 판독자가 임상정보를 받은 상태의 악성·양성 감별 정확도가 **76.0%**였습니다.

미리 분명히 해 두겠습니다. 이 연구는 **감시나 선별이 아닙니다.** 이미 발견된 병변을 간암과 혈관종으로 가르는 **감별 보조**입니다.

> 무대: 네 컷에는 라벨이 없다. 하나씩 짚고 클릭해 공개한다.

3. 그 76%는 어디서 온 숫자인가 — 35초

그 76%의 출처입니다. 중국 13개 병원 **전향적 다기관** 연구이고, 15년 이상 경력 전문의 **236명**이 익명화된 동영상을 임상정보와 함께 독립 판독했습니다.

다만 **악성 대 양성 이분**이고 양성이 19.3%뿐이며, **실제 진료가 아닌 동영상 판독 과제**였습니다. 이 두 가지 한계를 안고 읽어야 합니다.

> 무대: 사람 성적의 조건을 먼저 깔아 둔다. 뒤에서 AI 수치를 말할 때 비교선이 된다.

---

4. 확률이 아니라 "닮음" — 50초

그 연구는 한 가지를 더 보여줍니다. **영상에 임상정보를 결합한 AI는 84.7%였고, 영상만 쓴 모델은 판독자와 같은 76.0%**였습니다. 즉 **이득은 영상이 아니라 임상정보에서** 왔습니다.

그런데 **지금 대부분의 AI는 confidence 한 숫자만 내고, 그 값으로 label을 정합니다.** 그 숫자가 틀리면 판독자는 검증할 수단이 없습니다.

그래서 **세 개의 output**을 내는 모델을 만들었습니다.

- **Confidence** — 지금까지 AI가 내던 softmax 값. 보정이 안 된 값이라 확률이 아니라 **결정 강도**로 부릅니다.
- **HCC cosine** — **전형 HCC와 얼마나 닮았는지**, 즉 **전형성**입니다.
- **Δscore** — HCC cosine에서 혈관종 cosine을 뺀 값, **어느 쪽에 더 가까운가**입니다.

데이터는 공개 데이터셋 SMC-LUD clean subset, **744명 2,656장**을 **환자 단위**로 나눴습니다.

> 무대: 이미지 → 인코더 → 임베딩 → 세 지표 흐름을 한 번만 보여준다.

---

5. 인코더 내부 — 15초

구조는 한 줄로만 말씀드리겠습니다. 왼쪽은 합성곱이 특징 맵을 채우고, 오른쪽은 **CLS 토큰이 패치를 하나로 종합**합니다. 중요한 것은 **세 지표가 전부 이 임베딩 하나에서 나온다**는 점입니다. **모델 구조와 학습 설정은 질의 시간에 자세히 설명드리겠습니다.**

> 무대: 여기서 절대 멈추지 않는다. 15초 안에 다음 장으로 넘어간다.

---

6. SupCon은 임베딩의 모양을 바꾼다 — 30초

코사인은 SupCon 없이도 계산됩니다. 다만 그때 값은 흩어져 있어 **증례별로 읽을 수가 없습니다.** SupCon을 걸면 **같은 클래스는 모으고 다른 클래스는 밀어냅니다** — 미학습 HCC의 **94.7%에서 점수가 올라가고**, 코사인이 **증례별로 쓸 수 있는 값**이 됩니다. 분포와 검정 수치는 **질의 시간에** 말씀드리겠습니다. 대가는 Δscore 감소이고, 뒤에서 짚겠습니다.

> 무대: 수치·p값은 읽지 않는다. "읽을 수 있는 값이 됐다" 한 문장만 남긴다.

---

7. 같은 모델, 두 운영점 — 70초

성능입니다. 왼쪽 표의 두 열만 보시면 됩니다. 왼쪽은 관행대로 **확률을 0.5에서**, 오른쪽은 닮음 지표를 **검증 세트의 Youden 지점**에서 잘랐습니다.

확률 쪽은 HCC 여섯 장을 놓치고, 닮음 쪽은 혈관종 한 장만 HCC로 올립니다. 즉 **어디서 자르느냐가 민감도와 특이도를 맞바꿉니다.**

두 가지를 분명히 하겠습니다. 첫째, **두 운영점의 차이는 유의하지 않습니다** — 불일치가 여섯 대 하나, McNemar p는 0.125로 0.05보다 큽니다. 둘째, 세 출력의 AUROC가 모두 1.000이라 **DeLong 검정이 정보를 주지 않습니다.** 그래서 **우월도 비열등도 주장하지 않습니다.**

오른쪽 표의 컷오프와 등가 구간은 **둘 다 검증 세트에서** 구했습니다. 등가 구간은 같은 혼동행렬을 내는 임계값의 폭이고, 컷오프는 언제나 그 안에 있습니다 — 닮음 지표는 구간의 위쪽 끝이 곧 컷오프입니다. 테스트에서는 혈관종 한 장이 그보다 조금 위로 올라와 위양성이 한 건 났는데, **테스트에 맞춰 컷오프를 올리지는 않았습니다.** 그래서 외부 코호트에서 다시 정해야 합니다.

> 무대: "동등/비열등/개선"은 입에 올리지 않는다. 표의 두 열만 손으로 짚는다.

---

8. 닮음 점수가 실제로 움직였다 — 25초

왼쪽은 실제 HCC의 코사인 분포입니다. SupCon 후 **0.9 근처로 모이고**, 상승은 **전형에서 멀던 증례**에서 컸습니다 — 하위 10%가 크게 올라왔습니다. 즉 **아리까리했던 증례가 전형 HCC 쪽으로 정렬**된 것입니다. 다만 이건 **해석의 근거**이고 **성능이 좋아졌다는 근거**

가 아닙니다. 분포 통계는 질의 시간에 말씀드리겠습니다.

> 무대: 25초. 여기서 멈추면 §7의 결론이 약해진다. 한 문장씩만.

---

9. 혈관종처럼 보이는 HCC 4예 — 40초

혈관종처럼 보이는 HCC 4예를 실제로 넣어 봤습니다. 문헌에 보고된 고에코 HCC — 후방강화 동반, halo, 혈관종과 나란히 — 사람이 봐도 어려운 것들입니다. **세 출력 모두 4예 전부 HCC로 분류했습니다.**

다만 **proof-of-concept**입니다. n이 4이고, 출판 figure에서 온 저해상도·타 장비 영상이라 domain shift가 큽니다. **민감도 추정치로 읽으면 안 됩니다.**

---

10. 차이는 유의하지 않다 — 다만 실패하는 지점이 다르다 — 55초

가장 중요한 슬라이드입니다. 표에 두 줄만 있습니다.

첫 줄 — 확률 0.5가 놓친 HCC 여섯 장은, **같은 케이스의 닮음 점수가 모두 HCC 쪽**입니다. 확률만 경계에 눌린 것입니다.

둘째 줄 — 닮음 지표의 유일한 위양성은 실제 혈관종 한 장이고, 그 장은 **확률로는 정답**이 되는 케이스입니다.

정리하면 **실패하는 케이스가 서로 다릅니다.** 다만 차이는 유의하지 않으므로 — 불일치 여섯 대 하나, p는 0.125 — **닮음 지표가 확률을 개선한다고 주장하지 않습니다.** 확률이 애매한 구간에서 보조 판단을 주는 **새 지표**로 제안하고, 컷오프는 외부 코호트에서 다시 계산하는 것을 전제로 둡니다.

> 무대: '개선'이라는 단어를 쓰지 않는다. '다른 지점에서 실패한다'까지가 오늘의 결론이다.

---

11. Novelty와 한계 — 50초

남은 것은 — **한 모델에서 확률과 닮음 판단을 케이스 단위로 함께 낸다**는 것, **판독자가 이미 하는 "닮음" 판단을 숫자로 남긴다**는 것, 그리고 **지표마다 운영점과 등가 구간을 함께 제시한다**는 것입니다.

한계는 분명합니다. **단일기관이라 외부 검증이 없습니다. AUROC가 1.000이라 최적 컷오프가 유일하지 않고**, 두 운영점의 차이도 유의하지 않습니다. **Δscore는 오히려 감소했고, 닮음 상승은 SupCon 목적함수의 귀결이지 임상 타당성의 독립 증거가 아닙니다.** 배경 간 정보가 없어 층화가 불가능하고 단축경로 학습 가능성도 배제할 수 없습니다.

지금 데이터로는 **성능 차이가 유의하지 않습니다.** 그래서 이 지표의 값어치는 **추가 연구에서만** 정해집니다. 후속 연구에서 닮음 점수가 유의하게 도움이 된다면, **혈관종으로 follow-up 하기로 한 케이스 안에 섞여 있을 수 있는 HCC를 구제**하는 데 쓸 수 있습니다. 다만 이건 **가설**이고, 오늘 수치로는 아무것도 보장하지 않습니다.

다음 단계는 **다기관 외부 검증에서 컷오프 재산출, 판독자 대상 전향적 비교, AFP·조영증강 영상과의 비교**입니다.

> 질문 시 답변(말하지 않고 대기): 닮음 점수의 정의는 병변 임베딩과 학습 데이터 전형 프로토타입의 **코사인 유사도 평균**이고, 소프트맥스 확률이 아니며 보정된 확률도 아니다. Grad-CAM을 왜 안 넣었는지 물으면: 배경 간 라벨이 없으면 heatmap이 병변을 보는지 배경을 보는지 구분할 수 없어 오해를 만들 수 있다고 답한다.

---

12. 감사 — 10초

이상입니다. 오늘 말씀드린 것은 두 가지입니다. **닮음 점수라는 두 번째 숫자를 만들었다**는 것, 그리고 **그 숫자가 아직 임상적 이득을 입증하지 못했다**는 것.

마지막 장 QR은 **지금 이 자리에서 돌려볼 수 있는 웹 데모**입니다. 설치도 로그인도 필요 없고 사진은 기기 밖으로 나가지 않습니다.

질문과 토론을 환영합니다. 감사합니다.

토론 — "cosine 점수 + SupCon" 주장의 찬성측과 반대측

> 목적: 발표·질의에서 이 주장을 어디까지 밀지 정한다. **모든 수치는 `raw_cosprobe_effnet_*.csv`(n=798)에서 재계산해 재현했다.**

팩트 (재현된 수치)

항목	CE only	CE + SupCon	비고
true HCC(n=417) HCC cosine 중앙값	0.882	**0.970**	상승
true HCC HCC cosine 평균 ± SD	0.783 ± 0.256	**0.908 ± 0.160**	Wilcoxon p<0.001
true HCC 하위 10% / 최솟값	0.489 / −0.472	**0.762 / −0.005**	꼬리 제거
true HCC 분산	0.0656	**0.0257 (−60.7%)**	Pitman-Morgan p<0.001
true HEM(n=381) hem cosine 분산	0.00253	**0.00003 (−98.7%)**	381/381 전부 상승
개별 증례 상승 비율 (HCC)	—	**395/417 = 94.7%**	하락 22예
상승폭 vs 기준점 상관	—	**r = −0.80**	낮을수록 크게 상승
true HCC hem cosine (교차)	−0.631	**−0.108 (+0.52)**	다른 클래스 쪽으로 이동
true HEM hcc cosine (교차)	−0.701	**−0.226 (+0.48)**	다른 클래스 쪽으로 이동
Δscore 클래스 간격	3.163	**2.289 (−27.6%)**	판별 여유 감소
단독 AUROC (Test)	~1.000 (cosine FN3)	1.000 (FP1)	천장

찬성측 (SupCon이 이 지표를 "쓸 수 있는 값"으로 만든다)

1. **지표의 존재 이유**: 코사인은 원래 계산 가능하지만, CE-only 분포는 −0.5~1로 흩어져 **증례 단위 해석이 불가능**하다(HCC 평균 0.78, SD 0.26, 13/140 테스트 증례가 0.5 미만). "닮음 점수"라는 이름을 붙일 수 없는 상태다.
2. **꼬리 제거가 곧 임상적 의미**: 상승은 이미 전형인 증례가 아니라 **멀리 있던 증례**에서 일어났다(하위 10% +0.27 vs 상위 10% +0.03; 최솟값 −0.47→−0.005). 즉 "아리까리한 HCC"가 숫자상 전형 HCC와 같은 구역으로 들어왔다.

3. **재현성**: 백본을 ResNet50V2로 바꿔도 우측 이동 +0.104가 재현된다 → EfficientNet 특이적 현상이 아니라 목적함수의 효과.
4. **통계**: 동일 표본 전/후 비교에 맞는 paired 검정(Wilcoxon, Pitman-Morgan) 모두 $p<0.001$.
5. **실무적 가치**: 점수가 0.97이면 "전형 HCC", 0.4면 "비전형 — 확률만 보고 결정"이라고 **발표자가 판단 규칙을 세울 수 있다.** 점수의 폭이 좁아야 이 규칙이 성립한다.

반대측 (아직 "이득"이라고 부를 수 없다)

1. **동어반복 위험**: SupCon의 목적함수가 곧 "같은 클래스는 가깝게"다. 코사인 상승·분산 축소는 **손실함수가 충족된 결과**이지 병리적 타당성의 독립 증거가 아니다.
2. **교차 이동이 진짜 비용**: 각 클래스는 자기 원형뿐 아니라 **상대 원형 쪽으로도** 이동했다(HCC의 hem cosine −0.63→−0.11, 혈관종의 hcc cosine −0.70→−0.23). 두 분포가 서로 가까워져 **판별 여유(간격)가 3.16→2.29로 27.6% 줄었다.**
3. **증분 이득 없음**: 세 출력의 혼동행렬이 Test에서 동일(TP140/FP1/FN0/TN127), Val은 지표별로 100.0%/99.81%로 갈린다. **어떤 지표를 더해도 나아지지 않는다.**
4. **SupCon 없이는 안 된다는 주장은 성립하지 않음(심사 지적 수용)**: CE-only도 이미 천장(Test cosine FN3)이라 "SupCon 없이는 안 된다"는 주장은 우리 대조군이 스스로 반박한다. 심사에서 **철회한 표현("필수 정규화기", "단순 암기 배제", "초구면")은 재도입 금지**.
5. **"비전형"이 라벨로 존재하지 않는다**: 병리·배경간·비전형 주석이 없다. 우리의 "atypical"은 **사전 코사인이 낮았다**는 정의뿐 — 순환 정의다.
6. **회귀효과 혼입**: 기준점–상승폭 $r=-0.80$은 회귀효과의 전형적 서명이다. 94.7% 상승과 상위 10%의 소폭 상승(+0.02)이 순수 회귀는 아니라는 반증이지만, **사전등록 검정이 아니다.**
7. **경계가 얇아진 대가**: 압축은 "프로토타입에서 벗어났다"는 신호를 지운다. 실제로 그 얇아진 경계에서 혈관종 1장이 넘어갔다(그 장의 HCC-cosine +0.0325 = 혈관종 분포의 최댓값). 도메인 이동·진짜 비전형 병변이 들어오면 **자신 있게 HCC로 부를 위험**이 커진다.
8. **외부 검증·환자단위 통계 부재**(A3·A4 수용).

판정 — 발표에서 쓸 수 있는 문장

> **쓸 수 있음**: "SupCon은 코사인을 증례별로 읽을 수 있는 값으로 만든다 — 미학습 HCC 94.7%의 점수가 올라가고, 상승은 전형에서 멀던 증례에 집중되며(하위 10% +0.27), 분산이 60.7% 줄고, ResNet에서도 재현된다. 대가는 클래스 간격이 3.16에서 2.29로 좁아진 것이고, 그래서 증분 진단 이득은 없었다."

> **쓸 수 없음**: "SupCon이 없으면 안 된다", "임상 이득이 입증됐다", "비전형 HCC를 정상으로 구제한다", "코사인이 높으면 HCC다"(혈관종도 자기 원형에 0.985로 붙는다).
>
> **한 줄 요약**: 닮음 점수의 **해석 가능성**은 올라갔고, **판별력·임상 이득**은 올라가지 않았다. 두 축을 한 문장으로 뭉치지 않는다.

예상 질문과 답변

Q. cosine 점수는 정확히 무슨 값입니까? A. 확률이 아니라 **전형성**입니다. 이 병변의 임베딩이 훈련 세트 HCC 영상들의 평균 위치(원형)와 이루는 코사인입니다. 1에 가까우면 전형 HCC와 닮았다는 뜻이고, 0이나 음수면 전형 HCC와 다르다는 뜻입니다. 확률로 읽으면 안 됩니다 — 보정된 값이 아닙니다.

Q. SupCon을 안 쓰면 코사인은 못 구합니까? A. 구할 수 있습니다. 다만 그때는 분포가 −0.5에서 1까지 흩어져(평균 0.78, SD 0.26) 증례별로 읽을 수가 없습니다. SupCon을 걸면 미학습 HCC 417예 중 94.7%의 점수가 올라가고 하위 10%가 0.49에서 0.76으로 오릅니다. **지표를 쓸 수 있게 만드는 것**이 SupCon의 역할입니다. 다만 심사 지적대로 "없으면 안 된다"고는 말하지 않습니다 — CE 단독도 천장에 도달합니다.

Q. 코사인이 낮게 나온 증례는 어떻게 처리합니까? A. 그때는 코사인으로 판단할 수 없고 confidence를 봐야 합니다. SupCon 후에도 하위 10%는 0.76 수준이라 "0.9 이상이면 전형"이라는 규칙을 그대로 적용하면 일부는 비전형으로 남습니다. 이 연구는 그런 증례를 어떻게 다룰지에 대한 답을 주지 않습니다 — 전향적 연구가 필요합니다.

Q. 분산이 줄었다는 게 임상적으로 무슨 뜻입니까? A. "전형에서 멀던 증례가 AI 도움으로 전형 쪽으로 정렬된다"는 뜻입니다. 상승이 하위 10%에 집중되고(하위 +0.27 vs 상위 +0.03) 94.7%에서 점수가 오릅니다. 다만 이는 **표상 기하의 변화**이지 임상 결과의 개선이 아니고, 같은 압축이 클래스 간격을 3.16에서 2.29로 좁혀 판별 여유를 줄였습니다.

Q. 76%는 정말입니까? 출처를 확인했습니까? A. 확인했습니다. Yang Q, et al. *EBioMedicine* 2020;56:102777 §3.6과 Fig 4의 값입니다. 15년 이상 경력 초음파 전문의 236명이 외부검증 338 병변의 익명화 동영상을 임상정보와 함께 판독한 성적입니다. 다만 실제 진료가 아닌 동영상 판독 과제였고, 악성 대 양성 분처이며 80.7 대 19.3으로 불균형합니다.

Q. 임상정보를 다 준 상태였습니까? A. 원문 표현은 "accessible to clinical information"입니다. 제공된 것은 맞지만 어떤 항목인지는 부록 1.8에 있어 본문만으로는 열거할 수 없습니다. 그래서 "모든 임상정보"라고 단정하지 않습니다.

Q. 왜 AUROC가 1.000입니까? A. 정제된 clean subset이고, HCC는 병리확진이나 혈관종은 영상 기준이라 참조표준이 비대칭입니다. 그래서 높은 AUROC를 자랑으로 쓰지 않고, 천장효과로 지표 간 우열을 판정할 수 없다고만 말합니다.

Q. 그래서 이 지표를 임상에 쓰라는 겁니까? A. 아닙니다. 방법론적 실현까지입니다. 증분 이득이 입증되지 않았고, decision curve analysis도 하지 않았습니다.

Q. cosine 점수를 한 줄로 정의하면? A. 병변 임베딩과 전형 HCC 프로토타입의 코사인 유사도 평균입니다. 임베딩은 CLS 토큰 128차원이고, 프로토타입은 학습 데이터에서 만든 평균 벡터입니다. 혈관종 프로토타입에 대해서도 같은 값을 내고, 둘의 차이가 Δscore입니다. 확률이 아니라 방향의 닮음이고, 0에서 1 사이로 보정된 값도 아닙니다.

Q. 이 점수가 HCC를 놓친 케이스를 줄일 수 있습니까? A. 이 데이터로는 답할 수 없습니다. 증분 이득이 0이었습니다. **가설**로서는 그렇게 쓸 수 있다고 봅니다 — 혈관종으로 follow-up 하기로 한 케이스 안에 비전형 HCC가 섞여 있을 수 있고, 닮음 점수가 그걸 한 번 더 걸러주는지가 다음 질문입니다. **추가 연구에서 분류 성능에 유의한 개선이 확인될 때만** 말할 수 있는 이야기이고, 오늘은 그 검증 설계를 제안한 것까지입니다.

Q. Δscore는 왜 씁니까? A. 대비 지표입니다. 그런데 SupCon 후 1.508에서 1.076으로 감소했습니다 — 두 클래스가 서로 가까워졌기 때문입니다. 정의는 했지만 이 데이터로는 타당성을 지지할 근거가 없다고 보고합니다.